

UNIVERSIDAD SAN FRANCISCO DE QUITO USFQ

Colegio de Ciencias e Ingenierías

Diseño e implementación de un índice de riesgo de corrupción basado en preguntas acusatorias del portal de contratación pública ecuatoriano para procesos de Subasta Inversa Electrónica

Daniela Samantha Salazar Verdezoto

Ingeniería en Ciencias de la Computación

Trabajo de fin de carrera presentado como requisito para
la obtención del título de
Ingeniera en Ciencias de la Computación

Quito, 13 de mayo de 2026

© DERECHOS DE AUTOR

Por medio del presente documento certifico que he leído todas las Políticas y Manuales de la Universidad San Francisco de Quito USFQ, incluyendo la Política de Propiedad Intelectual USFQ, y estoy de acuerdo con su contenido, por lo que los derechos de propiedad intelectual del presente trabajo quedan sujetos a lo dispuesto en esas Políticas.

Asimismo, autorizo a la USFQ para que realice la digitalización y publicación de este trabajo en el repositorio virtual, de conformidad a lo dispuesto en la Ley Orgánica de Educación Superior del Ecuador.

Nombres y apellidos: Daniela Samantha Salazar Verdezoto

Código: 00329368

Cédula de identidad: 1723669857

Lugar y fecha: Quito, mayo de 2026

ACLARACIÓN PARA PUBLICACIÓN

Nota: El presente trabajo, en su totalidad o cualquiera de sus partes, no debe ser considerado como una publicación, incluso a pesar de estar disponible sin restricciones a través de un repositorio institucional. Esta declaración se alinea con las prácticas y recomendaciones presentadas por el Committee on Publication Ethics COPE descritas por Barbour et al. (2017) Discussion document on best practice for issues around theses publishing, disponible en <http://bit.ly/COPETheses>.

UNPUBLISHED DOCUMENT

Note: The following capstone project is available through Universidad San Francisco de Quito USFQ institutional repository. Nonetheless, this project – in whole or in part – should not be considered a publication. This statement follows the recommendations presented by the Committee on Publication Ethics COPE described by Barbour et al. (2017) Discussion document on best practice for issues around theses publishing available on <http://bit.ly/COPETheses>.

Resumen

La corrupción en la contratación pública es uno de los principales desafíos para la eficiencia del gasto estatal y la transparencia en América Latina. En Ecuador, el Sistema Oficial de Contratación Pública (SOCE) centraliza información detallada de los procesos contractuales, incluyendo preguntas y respuestas entre proveedores y entidades contratantes. Sin embargo, estos datos textuales no estructurados han sido poco aprovechados como fuente para la detección temprana de señales de riesgo.

Esta tesis aborda dicha brecha mediante el diseño e implementación de índices de riesgo basados en la identificación de preguntas acusatorias en procesos de Subasta Inversa Electrónica (SIE). Para ello, se utilizan técnicas de Procesamiento de Lenguaje Natural (PLN) y modelos de *Machine Learning* previamente desarrollados en el proyecto Kapak. El objetivo es transformar predicciones a nivel de pregunta en medidas agregadas a nivel de proceso contractual, capaces de capturar presencia, intensidad y consenso de señales textuales de posible riesgo.

Metodológicamente, se revisan modelos existentes bajo una lógica de perfiles diferenciados, considerando sensibilidad, precisión e interpretabilidad. A partir de estos modelos, se implementa un pipeline computacional que calcula índices binarios, probabilísticos y de consenso. Además, se incorpora un esquema de *LLM as a judge* como validación semántica complementaria, alineando un prompt frente a etiquetas humanas y utilizando el LLM para construir una densidad acusatoria de referencia a nivel de proceso.

Como resultado, se implementa un sistema de índices basado en siete modelos iniciales y organizado en tres enfoques complementarios: densidad binaria, promedio probabilístico y consenso entre modelos. En conjunto, la tesis aporta un marco metodológico para transformar información no estructurada en medidas interpretables de priorización analítica, sin asumirlas como evidencia concluyente de corrupción.

Palabras clave: corrupción, contratación pública, machine learning, procesamiento de lenguaje natural, índice de riesgo, preguntas acusatorias, Subasta Inversa Electrónica, SOCE, LLM-as-a-judge.

Abstract

Public procurement corruption is one of the main challenges for the efficiency of public spending and transparency in Latin America. In Ecuador, the Official Public Procurement System (SOCE) centralizes detailed information on procurement processes, including questions and answers exchanged between suppliers and contracting entities. However, these unstructured textual data have been underused as a source for the early detection of risk signals.

This thesis addresses that gap through the design and implementation of risk indices based on the identification of accusatory questions in Electronic Reverse Auction (SIE) processes. To this end, it uses Natural Language Processing (NLP) techniques and Machine Learning models previously developed within the Kapak project. The objective is to transform question-level predictions into aggregated measures at the procurement-process level, capable of capturing the presence, intensity, and consensus of textual signals of potential risk.

Methodologically, existing models are reviewed through a differentiated-profile approach, considering sensitivity, precision, and interpretability. Based on these models, a computational pipeline is implemented to calculate binary, probabilistic, and consensus-based indices. In addition, an LLM-as-a-judge scheme is incorporated as a complementary semantic validation mechanism, aligning a prompt against human labels and using the LLM to construct a reference accusatory density at the process level.

As a result, the thesis implements an index system based on seven initial models and organized around three complementary approaches: binary density, probabilistic average, and model consensus. Overall, the thesis contributes a methodological framework for transforming unstructured information into interpretable measures for analytical prioritization, without treating them as conclusive evidence of corruption.

Keywords: corruption, public procurement, machine learning, natural language processing, risk index, accusatory questions, Electronic Reverse Auction, SOCE, LLM-as-a-judge.

Tabla de contenidos

Resumen	3
Abstract.....	4
Tabla de contenidos	5
Índice de tablas.....	6
Índice de figuras.....	7
Introducción.....	8
Estado del arte	10
Medición del riesgo de corrupción mediante proxys.....	10
Uso de datos no estructurados y PLN en el sector público.	11
Selección de modelos de Machine Learning y desafíos de evaluación.	11
Construcción de indicadores e índices de riesgo.	13
Uso de modelos de lenguaje como jueces semánticos.....	14
Descripción del contexto y los datos.....	16
Sistema Oficial de Contratación Pública (SOCE).	16
Proyecto Kapak.	17
Metodología.....	17
Enfoque metodológico general.....	17
Antecedente técnico y punto de partida de los modelos.....	18
Criterios de selección de modelos.....	19
Diseño de los índices a nivel de proceso.	21
Uso de LLM como juez semántico complementario.	23
Resultados.....	27
Resultados de la selección de modelos.	27
Índices comparados contra “LLM as a judge”.	31
Discusión	47
Interpretación general de los resultados.....	47
Discusión sobre la evolución de la propuesta del índice.....	48
Selección del modelo con mayor alineación frente al LLM.	48
Limitaciones del estudio.	54
Conclusiones.....	56
Recomendaciones y trabajos futuros.....	59
Referencias y bibliografía.....	61

Índice de tablas

Tabla 1. Criterios y filtros de selección de modelos.....	21
Tabla 2. Características del primer perfil de modelo seleccionado	28
Tabla 3. Métricas obtenidas en la reproducción del primer perfil de modelo seleccionado .	28
Tabla 4. Características del segundo perfil de modelo seleccionado	29
Tabla 5. Métricas obtenidas en la reproducción del segundo perfil de modelo seleccionado	29
Tabla 6. Características del tercer perfil de modelo seleccionado	30
Tabla 7. Métricas obtenidas en la reproducción del segundo perfil de modelo seleccionado	30
Tabla 8. Distribución de conjuntos utilizados para la alineación, validación, y test del prompt	33
Tabla 9. Métricas de desempeño de las distintas versiones del prompt	35
Tabla 10. Resultados finales del Prompt 15 sobre el subconjunto de test depurado	35
Tabla 11. Comparación de los modelos frente al LLM.....	36
Tabla 12. Comparación de los modelos frente a la etiqueta humana	37
Tabla 13. Características de la muestra de procesos utilizada para la evaluación con LLM	39
Tabla 14. Métricas de similitud distribucional entre los índices por proceso y el LLM	40
Tabla 15. Correlación y solapamiento entre los índices por proceso y el LLM.....	45
Tabla 16. Desempeño de clasificación binaria de los índices por proceso frente al LLM...	46

Índice de figuras

Figura 1. Distribución comparada de proporción de preguntas acusatorias por proceso entre LLM e ID_bin_lr	41
Figura 2. Distribución comparada de proporción de preguntas acusatorias por proceso entre LLM e ID_prob_rf.....	42
Figura 3. Curvas KDE individuales de cada índice frente al LLM	43
Figura 4. Curvas KDE superpuestas de cada índice frente al LLM	44

Introducción

La contratación pública constituye un componente esencial para la ejecución de políticas públicas. Debido al volumen de fondos involucrados, la complejidad de los procesos y la interacción entre múltiples actores, este ámbito se encuentra expuesto a riesgos de corrupción y prácticas irregulares. Esta problemática ha impulsado el desarrollo de herramientas analíticas orientadas a identificar señales tempranas de riesgo mediante el uso de datos administrativos, indicadores estructurados y técnicas de ciencia de datos.

En el contexto ecuatoriano, el Sistema Oficial de Contratación Pública (SOCE), administrado por el Servicio Nacional de Contratación Pública (SERCOP), almacena información detallada sobre los procesos contractuales. Esta información incluye tanto datos estructurados (montos, fechas, entidades contratantes, proveedores y tipos de procedimiento) como datos no estructurados, entre ellos los registros textuales de preguntas y respuestas entre proveedores y entidades contratantes. Aunque el acceso a estos datos ha mejorado significativamente, persiste una limitación metodológica en la interpretación y cuantificación de los contenidos textuales como fuente de señales de riesgo.

Dentro de estos registros, las preguntas acusatorias constituyen una fuente particularmente relevante de información. Estas pueden entenderse como cuestionamientos formulados por oferentes que expresan dudas, señalamientos o posibles inconsistencias sobre las condiciones del proceso contractual. En algunos casos, estas preguntas pueden sugerir preocupaciones relacionadas con direccionamiento, favoritismo, restricciones indebidas, falta de transparencia o posibles irregularidades. Por esta razón, pueden funcionar como un *proxy* de riesgo percibido dentro del proceso. Sin embargo, su uso ha sido principalmente cualitativo y no ha sido incorporado de manera sistemática en índices reproducibles a nivel de proceso contractual.

Esta investigación se desarrolla en el marco del proyecto Kapak, una iniciativa orientada a la construcción de indicadores de riesgo de corrupción en la contratación pública ecuatoriana. En particular, la tesis se enfoca en el diseño e implementación de índices de riesgo derivados de la clasificación automática de preguntas acusatorias en procesos de Subasta Inversa Electrónica (SIE), con énfasis en el año 2021. El trabajo parte de modelos de *Machine*

Learning previamente desarrollados en el proyecto Kapak y busca transformar sus salidas a nivel de pregunta en medidas agregadas e interpretables a nivel de proceso.

El objetivo principal de esta tesis es construir un sistema de índices que permita capturar distintas dimensiones de la señal textual de riesgo: la presencia de preguntas acusatorias, la intensidad probabilística de dicha señal y el consenso entre modelos. Para ello, se implementan índices binarios, probabilísticos y de votación o consenso. Este enfoque permite analizar el riesgo textual desde perspectivas distintas, en lugar de reducirlo a una única medida cerrada.

Adicionalmente, la investigación incorpora un esquema de *LLM as a judge* como mecanismo de validación semántica complementaria. Para ello, se alinea iterativamente un prompt frente a etiquetas humanas con el fin de clasificar preguntas como acusatorias o no acusatorias. Posteriormente, el LLM se utiliza para clasificar preguntas completas de una muestra de procesos de 2021 y construir una densidad acusatoria de referencia a nivel de proceso. Esta señal no se interpreta como una verdad definitiva, sino como una referencia semántica adicional para contrastar el comportamiento de los índices construidos.

En este trabajo, el término “riesgo” no se refiere a la existencia comprobada de actos de corrupción, sino a la presencia de señales textuales que podrían asociarse con posibles irregularidades o tensiones dentro del proceso contractual. En consecuencia, los índices propuestos deben entenderse como herramientas de priorización analítica y no como instrumentos de imputación o prueba concluyente de corrupción.

El documento se organiza de la siguiente manera. En primer lugar, se presenta una revisión del estado del arte sobre medición del riesgo de corrupción mediante *proxys*, uso de datos no estructurados y procesamiento de lenguaje natural en el sector público, construcción de índices y uso de LLMs como jueces semánticos complementarios. Posteriormente, se describe el contexto de los datos y la metodología adoptada, incluyendo la selección de modelos, el diseño de los índices y el procedimiento de validación con LLM. A continuación, se presentan los resultados obtenidos para una muestra de procesos SIE de 2021. Finalmente, se desarrollan la discusión, las limitaciones, las recomendaciones y las conclusiones del trabajo.

Estado del arte

Medición del riesgo de corrupción mediante proxys.

La medición de la corrupción ha enfrentado históricamente una dificultad central: se trata de un fenómeno parcialmente oculto, de observación indirecta y de verificación compleja. Por esta razón, una parte importante de la literatura inicial se apoyó en índices de percepción, como los desarrollados por Transparencia Internacional o el Banco Mundial. Aunque estos instrumentos permitieron realizar comparaciones sistemáticas entre países e instituciones, han sido objeto de críticas por su dependencia de juicios subjetivos, la posible homogeneidad de sus fuentes y su sensibilidad a sesgos de percepción (Fazekas & Kocsis, 2020).

Como respuesta a estas limitaciones, surgió un cambio metodológico orientado al uso de datos administrativos objetivos, especialmente en el ámbito de la contratación pública, para construir indicadores de riesgo de corrupción basados en señales observables o *red flags*. En esta línea, Fazekas et al. (2016) proponen un Índice de Riesgo de Corrupción (CRI) sustentado en variables del proceso contractual, con el objetivo de aproximarse empíricamente a patrones asociados a la restricción de la competencia o la manipulación procedimental. Este enfoque fortalece la replicabilidad, reduce la dependencia de percepciones externas y permite trasladar el análisis hacia trazas observables del comportamiento institucional.

No obstante, la literatura también evidencia que los proxys tradicionales no son suficientes por sí solos. Ferwerda et al. (2017) señalan que solo un subconjunto de las señales comúnmente utilizadas posee un verdadero poder discriminatorio, mientras que Decarolis y Giorgiantonio (2022) muestran que los actores pueden adaptarse a las *red flags* procedimentales más conocidas, reduciendo su capacidad para detectar riesgo de manera consistente. En consecuencia, aunque los indicadores estructurados siguen siendo metodológicamente valiosos, su utilidad aumenta cuando se complementan con fuentes menos rígidas y más difíciles de neutralizar *ex ante*.

En este contexto, el uso de preguntas acusatorias como proxy resulta teóricamente defendible. A diferencia de otras señales puramente administrativas, estas preguntas no describen únicamente una característica formal del proceso, sino que expresan fricción percibida por los oferentes en relación con la transparencia, la equidad o la legalidad de la

contratación. Desde esta perspectiva, las preguntas acusatorias pueden interpretarse como una huella textual del riesgo percibido por actores directamente involucrados en la competencia. Su valor no radica en constituir evidencia concluyente de corrupción, sino en funcionar como una señal temprana, semánticamente rica y operativamente útil para priorizar procesos de revisión.

Uso de datos no estructurados y PLN en el sector público.

La incorporación del Procesamiento de Lenguaje Natural (PLN) ha ampliado el horizonte metodológico al permitir la explotación de información cualitativa contenida en pliegos, especificaciones técnicas y fases de aclaración, tradicionalmente ignoradas por los modelos tabulares.

Estudios recientes muestran que arquitecturas como Bi-LSTM y modelos basados en transformadores (por ejemplo, BERT) superan a enfoques clásicos al capturar ambigüedades semánticas, restricciones técnicas implícitas y patrones lingüísticos asociados a limitación de competencia (Lima et al., 2023). En América Latina y Asia, la evidencia empírica indica que el lenguaje jurídico y los intercambios discursivos entre oferentes y entidades contratantes contienen señales de riesgo que no quedan reflejadas en variables estructuradas.

En consecuencia, el análisis del texto generado en el portal SOCE representa una oportunidad metodológica relevante para identificar patrones de restricción anticompetitiva difíciles de neutralizar mediante simples ajustes formales en los procedimientos administrativos.

Selección de modelos de Machine Learning y desafíos de evaluación.

La selección de modelos en tareas de detección de riesgo no puede reducirse a la comparación de una única métrica agregada. En contextos de clasificación desbalanceada, como la detección de preguntas acusatorias, métricas como la exactitud global pueden resultar engañosas, ya que un modelo puede obtener un valor elevado simplemente por clasificar correctamente la mayoría de los casos negativos. Por esta razón, la literatura especializada recomienda priorizar métricas más sensibles al desempeño sobre la clase minoritaria, como *precision*, *recall*, *F1-score* y, en determinados contextos, el área bajo la curva precisión-recall (*AUPRC*), especialmente cuando la prevalencia de la clase positiva es muy baja (Gallego et al., 2021).

No obstante, en contextos institucionales la evaluación no depende únicamente del rendimiento estadístico. La literatura sobre modelos predictivos aplicados a decisiones públicas y regulatorias subraya que los errores no tienen costos simétricos. Un falso negativo puede implicar dejar fuera del escrutinio un proceso potencialmente irregular, mientras que un falso positivo puede derivar en la revisión adicional de un caso que finalmente resulta regular. Este desequilibrio obliga a considerar explícitamente el *trade-off* entre sensibilidad (*recall*) y precisión (*precision*), no solo como un problema técnico, sino como una decisión con implicaciones operativas e institucionales.

A esta dimensión se suma la exigencia de interpretabilidad. En sistemas de supervisión pública, los organismos de control no requieren únicamente modelos con buen desempeño, sino herramientas que produzcan resultados trazables, defendibles y comprensibles, capaces de justificar la apertura de revisiones o investigaciones. En este sentido, Salazar et al. (2024) destacan la necesidad de articular la capacidad predictiva con la utilidad institucional, mientras que Steyerberg et al. (2010) argumentan que el desempeño de un modelo debe evaluarse de manera integral, considerando dimensiones como la discriminación, la calibración y la utilidad práctica.

Bajo esta perspectiva, la literatura reciente sugiere que la comparación de modelos debe abordarse de forma multidimensional. Harman y Scheuerman señalan que las evaluaciones basadas en un único criterio tienden a ocultar debilidades relevantes, mientras que estudios como Norberg et al. (2019) y Filho et al. (2025) muestran que un marco compuesto permite distinguir mejor entre alternativas que presentan desempeños similares en métricas globales, pero difieren en aspectos como la estabilidad, la resolución del *score* o su utilidad operativa. Este punto resulta especialmente relevante en la presente tesis, ya que el objetivo no es únicamente seleccionar el clasificador con “mejor desempeño” en abstracto, sino identificar modelos cuyas salidas sean efectivamente útiles para la construcción de un índice de riesgo a nivel de proceso.

En consecuencia, el problema de selección en esta investigación no se limita a identificar qué modelo clasifica mejor las preguntas acusatorias, sino también cuáles generan probabilidades o decisiones capaces de sostener un sistema más amplio de priorización de riesgo. Esto

justifica conceptualmente el uso de un marco de evaluación multidimensional, en lugar de depender de una única métrica resumen.

Construcción de indicadores e índices de riesgo.

La transformación de predicciones individuales en un índice a nivel de proceso constituye uno de los problemas metodológicos centrales de esta tesis. Mientras que la clasificación de una pregunta puede abordarse como una tarea binaria convencional, la construcción de un índice de riesgo contractual exige definir cómo se agregan múltiples señales parciales en una medida única, interpretable y útil para la priorización.

La literatura sobre índices compuestos ha utilizado tradicionalmente agregaciones lineales de indicadores binarios, generalmente mediante medias simples o ponderadas. Sin embargo, este enfoque supone que las señales son compensatorias y que su efecto puede resumirse adecuadamente en una combinación lineal. Frente a ello, la literatura contemporánea ha propuesto alternativas más expresivas. Entre estas se encuentran modelos probabilísticos de acumulación, como *Noisy-OR* o formulaciones inspiradas en la teoría de confiabilidad, que interpretan el riesgo como la probabilidad conjunta de ocurrencia de eventos críticos. Asimismo, destacan esquemas de *pooling* no lineal y enfoques de *Multiple Instance Learning* (MIL), donde cada contrato se modela como un conjunto de instancias textuales y la función de agregación depende de supuestos sobre cómo se manifiesta el riesgo en el conjunto documental (Fuduli et al., 2022).

Estas alternativas ponen en evidencia que la agregación no es un detalle técnico menor, sino una decisión metodológica con implicaciones sustantivas. Una regla de máximo privilegia la señal más intensa; una media enfatiza la intensidad promedio; una agregación binaria resalta la prevalencia de señales; y una combinación entre modelos puede interpretarse como una forma de robustez basada en consenso. En otras palabras, cada índice implica una hipótesis distinta sobre qué significa que un proceso sea riesgoso.

Adicionalmente, la literatura sobre calibración probabilística y teoría de decisión sugiere que, cuando el objetivo no es solo clasificar sino priorizar, las probabilidades continuas ofrecen ventajas importantes frente a decisiones binarias tempranas. Un *score* continuo preserva información sobre la intensidad relativa de la señal y permite ordenar observaciones, mientras que una clasificación binaria colapsa dicha información en una decisión basada en umbral.

Esto resulta especialmente relevante en contextos institucionales donde los recursos de revisión son limitados y el objetivo práctico es jerarquizar casos según su prioridad analítica.

Desde esta perspectiva, la utilidad de un índice no depende únicamente de su alineación con una línea base histórica, sino también de su comportamiento como *score*. Un buen índice debe evitar la saturación en unos pocos valores, conservar suficiente resolución para ordenar procesos, mantenerse relativamente estable frente a cambios en la composición de la muestra y, cuando sea posible, converger con otras señales plausibles del mismo fenómeno. Por ello, la literatura más reciente sobre evaluación de *scores* y modelos predictivos resulta especialmente pertinente para justificar marcos de selección multidimensionales, en los que no solo importa la capacidad de clasificación, sino también la calidad distribucional del puntaje, su robustez y su utilidad operativa para la priorización.

En este sentido, la presente tesis se inscribe en una línea de trabajo que trasciende la simple detección de preguntas acusatorias, al buscar formalizar la transición desde una predicción textual hacia un índice de riesgo a nivel de proceso. El aporte metodológico no radica únicamente en la aplicación de modelos de procesamiento de lenguaje natural al texto del SOCE, sino en la definición, comparación y justificación de distintas estrategias de agregación que permiten capturar la prevalencia, la intensidad y el consenso de la señal de riesgo. Por ello, la construcción del índice no debe entenderse como una etapa posterior o accesorio, sino como el núcleo conceptual del proyecto.

Uso de modelos de lenguaje como jueces semánticos.

En los últimos años, el uso de modelos de lenguaje como evaluadores automáticos, conocido como LLM-as-a-judge, ha surgido como una estrategia para tareas donde la evaluación requiere interpretación contextual, razonamiento semántico o aplicación de criterios cualitativos. Según Gu et al. (2026), este enfoque se define como el “uso de LLMs para evaluar objetos, acciones o decisiones con base en reglas, criterios o preferencias previamente establecidas”. A diferencia de métricas automáticas tradicionales, que suelen depender de coincidencias superficiales o reglas rígidas, el LLM como juez permite incorporar una evaluación más flexible y sensible al significado del texto. Esto resulta especialmente útil en tareas de clasificación, puntuación, comparación, verificación de hechos, revisión de contenido y anotación de datos a gran escala.

La relevancia de este enfoque se explica por la tensión entre dos formas tradicionales de evaluación. Por un lado, la evaluación humana suele considerarse el estándar de referencia, ya que permite interpretar matices, intención, contexto y ambigüedad (Gu et al., 2026). Sin embargo, es costosa, lenta y difícil de escalar. Por otro lado, las métricas automáticas son más rápidas y reproducibles, pero pueden ser demasiado inflexibles para capturar dimensiones semánticas complejas. En este contexto, el paradigma *LLM-as-a-judge* busca combinar la escalabilidad de los métodos automáticos con una capacidad de razonamiento más cercana a la evaluación humana, funcionando como una herramienta intermedia entre ambos enfoques.

Metodológicamente, los sistemas de *LLM-as-a-judge* suelen organizarse alrededor de un proceso estructurado que incluye el diseño del prompt, la selección del modelo, el post-procesamiento de las respuestas y la evaluación final. Las instrucciones pueden incorporar estrategias de *in-context learning*, ejemplos de evaluación (*few-shot prompting*) y criterios explícitos para guiar la decisión del modelo. Dependiendo de la tarea, el LLM puede producir puntajes, seleccionar entre opciones, realizar comparaciones por pares o responder preguntas binarias de tipo sí/no. En este sentido, el uso de un LLM para clasificar preguntas como acusatorias o no acusatorias se ajusta al tipo de evaluación binaria descrita en la literatura sobre este enfoque (Gu et al., 2026).

Un aspecto central de este paradigma es la necesidad de validar y alinear las respuestas del LLM frente a criterios humanos. La literatura plantea que el LLM puede funcionar como un “anotador virtual”, pero su confiabilidad debe evaluarse mediante comparación con anotaciones humanas o conjuntos de validación previamente revisados. Para ello se utilizan métricas como porcentaje de acuerdo, accuracy, precision, recall, correlación de Spearman o Cohen’s kappa. Esta validación es importante porque permite medir si el modelo está aplicando los criterios de evaluación de forma consistente con el juicio humano, antes de utilizarlo en tareas más amplias o en muestras de mayor escala.

No obstante, el uso de LLMs como jueces presenta limitaciones importantes. Los resultados pueden variar significativamente ante cambios pequeños en el prompt, en los ejemplos utilizados o en la versión del modelo. Además, se han identificado sesgos como preferencia por ciertas posiciones, sesgo hacia respuestas más largas, sobreconfianza, falta de

transparencia y tendencia a favorecer textos con detalles aparentemente concretos, aunque no necesariamente correctos. Por esta razón, la literatura advierte que el LLM no debe entenderse como reemplazo de la evaluación humana, sino como una herramienta que puede complementar y ampliar la capacidad de análisis, especialmente cuando se trabaja con grandes volúmenes de datos textuales.

En el contexto de esta tesis, el enfoque *LLM-as-a-judge* resulta pertinente porque la identificación de preguntas acusatorias requiere interpretar elementos semánticos que no siempre pueden capturarse mediante reglas o palabras clave. Clasificar una pregunta como acusatoria implica distinguir entre una solicitud técnica, una crítica normativa, una queja procedimental y una acusación directa de direccionamiento, favoritismo o irregularidad. Por ello, el LLM se utiliza como una referencia semántica complementaria, no como una verdad definitiva. Su función es apoyar la evaluación de los índices construidos, permitiendo contrastar si las señales agregadas por los modelos se alinean con una lectura contextual del lenguaje utilizado por los proveedores en los procesos de contratación pública.

Descripción del contexto y los datos

Sistema Oficial de Contratación Pública (SOCE).

En el Ecuador, el Sistema Oficial de Contratación Pública (SOCE) constituye la plataforma tecnológica central y la fuente primaria de información sobre las transacciones del Estado, siendo administrada y supervisada por el Servicio Nacional de Contratación Pública (SERCOP). El ecosistema del SOCE rige la publicación y ejecución de los procedimientos de contratación pública, garantizando en teoría los principios de legalidad, trato justo, transparencia y concurrencia. A través de este portal, las entidades contratantes y los proveedores interactúan dinámicamente en diversas fases, generando un repositorio digital de acceso público que documenta el ciclo de vida completo de cada adquisición.

Como resultado de esta dinámica, el SOCE genera un volumen masivo de registros que engloban tanto metadatos estructurados como documentos escritos y foros de interacción no estructurados. A pesar de la riqueza informativa de esta plataforma, la información textual originada en los foros y documentos del portal no suele sistematizarse para la detección de riesgos. Tradicionalmente, las auditorías y sistemas de control se enfocan en los datos estructurados (montos, fechas, estados), dejando el lenguaje natural y las quejas escritas de

los proveedores subutilizados debido a la falta de herramientas computacionales capaces de procesar y analizar texto a gran escala para identificar alertas tempranas de corrupción de forma proactiva.

Proyecto Kapak.

El Proyecto Kapak surge como una respuesta tecnológica ante la necesidad de auditoría masiva, consolidándose como una plataforma de indicadores diseñada para identificar sistemáticamente riesgos de corrupción en la compra pública ecuatoriana. La arquitectura de Kapak procesa los datos extraídos del SOCE para calcular alertas o “red flags” a nivel de proceso, de entidad contratante y de proveedor, agregando los resultados en un índice compuesto de riesgo.

Dentro de la matriz metodológica de este proyecto, el presente trabajo de titulación se enfoca en profundizar, optimizar y validar uno de sus componentes más complejos: la transformación de salidas de modelos de Machine Learning (ML) y Procesamiento de Lenguaje Natural (NLP) en un índice cuantificable. Específicamente, la tesis aborda el “Indicador 4”, diseñado para identificar procedimientos con posibles preguntas acusatorias.

Metodología

Enfoque metodológico general.

Este trabajo adopta un enfoque metodológico de tipo secuencial–iterativo, alineado con la lógica del Iterative Waterfall Model, utilizada con frecuencia en proyectos aplicados de ciencia de datos. Este enfoque permite organizar la investigación en fases claramente definidas (revisión teórica, análisis técnico, selección de modelos, diseño de índices, implementación computacional y evaluación), incorporando a la vez iteraciones controladas cuando los resultados parciales requieren ajustes en las decisiones metodológicas.

A diferencia de investigaciones orientadas al entrenamiento de modelos desde cero, esta tesis parte de modelos de clasificación previamente desarrollados en el marco del proyecto Kapak. Por ello, el objetivo principal no fue construir un nuevo clasificador a nivel de pregunta, sino revisar, reproducir y seleccionar modelos existentes para transformar sus salidas en índices de riesgo a nivel de proceso contractual.

En consecuencia, la metodología se organiza alrededor de cuatro ejes principales. Primero, la revisión técnica de los modelos previamente desarrollados y de sus resultados. Segundo, la definición de criterios de selección basados en perfiles operativos diferenciados, considerando el balance entre sensibilidad, precisión y desempeño general. Tercero, el diseño de distintas formas de agregación para construir índices a nivel de proceso, incluyendo índices binarios, probabilísticos y de consenso. Finalmente, la incorporación de un LLM como juez semántico complementario, utilizado para contrastar la coherencia de los índices con una lectura contextual de las preguntas acusatorias.

De esta manera, la metodología combina evaluación cuantitativa, diseño conceptual de indicadores y validación semántica complementaria, con el propósito de construir índices interpretables y útiles para la priorización de procesos de contratación pública.

Antecedente técnico y punto de partida de los modelos.

El punto de partida técnico de esta tesis corresponde al trabajo previo desarrollado por Roh (2024) en el marco del proyecto Kapak. Dicho trabajo abordó la detección automática de preguntas acusatorias en procesos de contratación pública ecuatoriana mediante técnicas de Procesamiento de Lenguaje Natural y modelos de Machine Learning. Para ello, se utilizó un dataset de 5005 preguntas etiquetadas manualmente como acusatorias o no acusatorias, con una distribución altamente desbalanceada entre clases.

A partir de este corpus, el trabajo previo evaluó múltiples combinaciones de representaciones textuales, técnicas de aumento de datos y algoritmos de clasificación. Entre las representaciones utilizadas se incluyeron métodos tradicionales como BoW y TF-IDF, embeddings preentrenados y representaciones generadas mediante modelos como text-embedding-3-large. Asimismo, se probaron distintos clasificadores clásicos y modelos de aprendizaje profundo, generando un conjunto amplio de resultados experimentales.

Esta tesis no parte del entrenamiento de modelos desde cero, sino de la revisión, reproducción y selección de modelos previamente desarrollados. En ese sentido, el objetivo metodológico no fue proponer un nuevo clasificador a nivel de pregunta, sino transformar las salidas de modelos existentes en índices de riesgo a nivel de proceso contractual. Por ello, los modelos

seleccionados funcionan como insumo para construir distintas formas de agregación: densidad binaria, promedio probabilístico y consenso entre modelos.

Criterios de selección de modelos.

La selección de los modelos finales no se realizó únicamente con base en una métrica global de desempeño, sino bajo una lógica de perfiles diferenciados, coherente con la teoría de costos del error en sistemas de alerta temprana. En el contexto de detección de riesgo en contratación pública, los errores de clasificación no tienen el mismo impacto institucional. Un falso negativo (FN) implica que un proceso potencialmente irregular no genera ninguna alerta y puede quedar fuera del escrutinio. En cambio, un falso positivo (FP) implica la revisión de un proceso que finalmente podría resultar regular.

Diversos trabajos recientes en dominios institucionales, clínicos e industriales han demostrado que el costo asociado a los falsos negativos (FN) y falsos positivos (FP) no es simétrico y depende del contexto operativo (Bui, 2026). En particular, en el contexto de monitoreo regulatorio bancario (AML/CFT), se establece explícitamente que “el costo regulatorio de los falsos negativos excede sistemáticamente al de los falsos positivos”. De manera análoga, en detección de riesgo de corrupción en contratación pública, omitir un proceso potencialmente irregular puede implicar un costo institucional mayor que revisar un proceso limpio.

Sin embargo, Riaz et al. (2025) advierten que una sobreabundancia de falsas alarmas degrada la aplicabilidad práctica del sistema. Por tanto, el diseño de un sistema de detección debe formalizar explícitamente el trade-off entre exhaustividad y confiabilidad.

Bajo este marco, se definieron tres perfiles de selección:

1. **Perfil de alta sensibilidad:** orientado a minimizar falsos negativos.
2. **Perfil de alta precisión:** orientado a minimizar falsos positivos.
3. **Perfil equilibrado:** orientado a lograr un balance entre falsos positivos y falsos negativos.

Las métricas consideradas para esta selección fueron las siguientes:

Binary Recall (sensibilidad): proporción de casos positivos correctamente detectados.

Binary Precision: proporción de predicciones positivas que corresponden efectivamente a casos reales.

Binary F1-Score: media armónica entre precisión y sensibilidad.

AUC-ROC: capacidad del modelo para discriminar entre clases independientemente de un umbral fijo.

Matriz de confusión (TP, FP, FN, TN): análisis detallado del comportamiento del modelo en términos absolutos.

A partir de estas métricas, se definieron filtros y criterios de ordenamiento específicos para cada perfil. Para el perfil de alta sensibilidad, se estableció como filtro mínimo un AUC-ROC ≥ 0.80 , y los modelos fueron ordenados priorizando: (1) maximizar recall, (2) minimizar falsos positivos y (3) maximizar F1 como criterio de desempate. Para el perfil de alta precisión, se aplicaron filtros más restrictivos: AUC-ROC ≥ 0.90 , recall ≥ 0.50 y F1 ≥ 0.58 . En este caso, el ordenamiento priorizó: (1) maximizar precision y (2) minimizar el número absoluto de falsos positivos. Finalmente, para el perfil equilibrado, se establecieron como filtros AUC-ROC ≥ 0.93 y FP ≤ 20 . El criterio de ordenamiento fue: (1) maximizar F1 y (2) maximizar recall como criterio de desempate.

A continuación, se muestra una tabla de resumen de los filtros y criterios para la selección de modelos:

Perfil	Filtros Mínimos	Criterios de Ordenamiento (Prioridad)
Alta Sensibilidad	AUC-ROC ≥ 0.80	1. Maximizar Recall 2. Minimizar Falsos Positivos 3. Maximizar F1 (Desempate)
Alta Precisión	AUC-ROC ≥ 0.90 Recall ≥ 0.50 F1 ≥ 0.58	1. Maximizar Precision 2. Minimizar número absoluto de FP
Equilibrado	AUC-ROC ≥ 0.93 FP ≤ 20	1. Maximizar F1-Score 2. Maximizar Recall (Desempate)

Tabla 1. Criterios y filtros de selección de modelos

Diseño de los índices a nivel de proceso.

Evolución de la propuesta del índice.

Inicialmente se consideraron distintas familias de agregación, incluyendo agregaciones lineales, enfoques acumulativos como Noisy-OR, pooling no lineal y estrategias de fusión entre modelos. Sin embargo, para la implementación principal se priorizaron tres familias de índices por su interpretabilidad y comparabilidad: densidad binaria, promedio probabilístico y consenso entre modelos.

Indicador binario de detección.

El sistema parte de una clasificación a nivel de pregunta. Para cada pregunta q de un proceso contractual, cada modelo produce una probabilidad $P \in [0,1]$ de que dicha pregunta sea acusatoria. A partir de esa probabilidad puede definirse también una decisión binaria in sujeta a un umbral de clasificación τ :

$$in = \begin{cases} 1 & \text{si } P \geq \tau \\ 0 & \text{si } P < \tau \end{cases}$$

Esta representación binaria resulta útil porque permite contar cuántas preguntas son marcadas como acusatorias dentro de cada proceso, mientras que la representación probabilística conserva la intensidad de la señal y evita perder información por el umbral.

Índice de intensidad binaria por proceso.

La primera métrica propuesta es el Índice de Densidad (ID_bin). Bajo este enfoque, cada pregunta se categoriza de forma binaria como acusatoria o no acusatoria, para posteriormente calcular la proporción de etiquetas positivas dentro de un proceso determinado:

$$ID_{bin} = \frac{1}{n} \sum_{i=1}^n in$$

donde ID_{bin} representa el índice binario por proceso, n representa el número de preguntas por proceso, y in representa preguntas acusatorias (1) y no acusatorias (0). Este indicador permite cuantificar qué fracción de las preguntas asociadas a un proceso corresponden a preguntas de naturaleza acusatoria. Su principal fortaleza reside en su fácil interpretación: un valor de 0.30 indica que el 30 % de las preguntas del proceso fueron detectadas como tales.

Índices probabilísticos promedio por proceso.

La segunda propuesta es el Índice de Probabilidad (ID_prob). Este preserva la naturaleza continua de las salidas del modelo. En lugar de convertir cada pregunta en una decisión binaria, se promedian directamente las probabilidades de todas las preguntas del proceso:

$$ID_{prob} = \frac{1}{n} \sum_{i=1}^n p_i$$

donde ID_{prob} es el índice de probabilidad por proceso, n corresponde al número de preguntas asociadas al proceso, y p_i representa la probabilidad por pregunta.

Este enfoque mide la intensidad promedio de cuan acusatorio es un proceso. Su ventaja es que aprovecha mejor la información del clasificador y permite distinguir entre procesos que tienen la misma cantidad de preguntas marcadas, pero con niveles distintos de confianza.

Índice de votación entre modelos por proceso.

La tercera propuesta final es un índice de votación entre los tres modelos seleccionados por probabilidad (ID_prob_weighted). Para cada pregunta, se combina la señal de los clasificadores mediante una regla de votación suave, de modo que el score consolidado refleje el consenso relativo entre modelos:

$$ID_{prob_weighted} = w_1 * P_model_1 + w_2 * P_model_2 + w_3 * P_model_3$$

donde $ID_{prob_weighted}$ representa el índice de votación para un proceso, w_i representa el peso del modelo i , y P_model_i representa el puntaje en probabilidad que el modelo i dio al proceso. Este último se calcula por promedio de las probabilidades de todas las preguntas de un proceso. Bajo este esquema, el peso de cada clasificador se determina a partir de su Brier Score, una métrica que evalúa la precisión de las predicciones probabilísticas. Al asignar una mayor ponderación a los modelos con un Brier Score más bajo, el índice prioriza a aquellos clasificadores que demuestran una mayor calibración y menor incertidumbre.

Justificación metodológica de la propuesta final.

La decisión de converger en estos tres enfoques responde a criterios de interpretabilidad, estabilidad empírica y utilidad analítica. El índice de densidad binaria ofrece una lectura clara para usos de tamizaje. Los índices probabilísticos promedio preservan resolución y permiten ordenar procesos con mayor fineza. El índice de votación agrega una capa de robustez al

combinar la evidencia de varios modelos. En conjunto, la familia final de índices evita la saturación de métodos acumulativos, mantiene valores comparables en el rango $[0,1]$ y permite analizar el riesgo desde perspectivas complementarias: prevalencia binaria, intensidad promedio y consenso entre modelos.

Uso de LLM como juez semántico complementario.

Justificación del LLM como referencia complementaria.

Esta investigación incorporó un esquema de *LLM as a judge* como mecanismo de validación semántica complementaria. El objetivo de este componente no fue reemplazar las etiquetas humanas ni asumir que el LLM constituye una verdad objetiva, sino disponer de una referencia adicional capaz de evaluar el contenido lingüístico de las preguntas desde una perspectiva más contextual.

Esta decisión responde a una limitación central del problema: la identificación de preguntas acusatorias no depende únicamente de palabras clave, sino de la interpretación del tono, la intención comunicativa, el grado de imputación y el contexto normativo de la pregunta. En contratación pública, una misma pregunta puede expresar una crítica técnica, una solicitud de aclaración o una acusación directa de direccionamiento, favoritismo o irregularidad. Por ello, el uso de un LLM permite incorporar una lectura semántica más flexible que la de una regla basada exclusivamente en términos específicos.

En este trabajo, el LLM fue utilizado en dos niveles. En primer lugar, a nivel de pregunta, se empleó para clasificar observaciones individuales como acusatorias o no acusatorias y comparar sus decisiones con las etiquetas humanas disponibles. En segundo lugar, a nivel de proceso, se utilizó para clasificar preguntas completas pertenecientes a procesos de contratación de 2021, con el fin de construir una medida agregada de densidad acusatoria por proceso. Esta segunda aplicación permitió generar una referencia semántica a nivel de proceso, necesaria para contrastar los índices contruidos en la tesis.

Es importante señalar que el LLM se interpreta únicamente como una referencia complementaria. Sus decisiones dependen del prompt, de los ejemplos incluidos, del modelo utilizado y de las reglas de clasificación proporcionadas. Por tanto, las comparaciones entre los índices y el LLM no buscan demostrar de manera definitiva qué índice es “correcto”, sino

evaluar qué índice presenta mayor consistencia relativa con una lectura semántica sistemática de las preguntas.

División de datos para alineación, validación y prueba.

Para implementar el esquema de *LLM as a judge*, se utilizó como punto de partida el dataset original de 5005 preguntas etiquetadas manualmente como acusatorias o no acusatorias. Se busca hacer particiones mediante muestreo estratificado, con el objetivo de tener diferentes conjuntos para realizar entrenamiento, validación, y pruebas, así como mantener proporciones similares entre clases en los distintos subconjuntos.

Inicialmente, el dataset fue dividido en dos conjuntos principales. El primero correspondió al conjunto de entrenamiento inicial, equivalente al 80% de los datos. El segundo correspondió al conjunto de test inicial, equivalente al 20% restante. Esta separación permitió reservar un conjunto independiente para evaluar el desempeño del prompt una vez finalizado el proceso de alineación, evitando que las métricas finales estuvieran sesgadas por ajustes realizados sobre los mismos datos.

A su vez, el conjunto de entrenamiento inicial fue dividido nuevamente en dos subconjuntos. El primero fue utilizado como fuente para seleccionar ejemplos de preguntas acusatorias y no acusatorias que serían incorporados dentro del prompt. Estos ejemplos funcionaron como guías semánticas para orientar al LLM sobre la frontera conceptual entre ambas clases. El segundo subconjunto fue utilizado como conjunto de validación del prompt. Su función fue evaluar iterativamente el desempeño de las distintas versiones del prompt sobre preguntas que no habían sido usadas como ejemplos.

Esta estructura permitió separar tres funciones metodológicas distintas: selección de ejemplos, validación del prompt y evaluación final. La separación es importante porque medir el desempeño del prompt sobre las mismas preguntas utilizadas como ejemplos podría sobreestimar su capacidad de generalización. Por ello, el conjunto de validación permitió observar si las instrucciones diseñadas funcionaban sobre nuevas preguntas antes de pasar a una evaluación independiente.

Diseño y alineación iterativa del prompt.

El proceso de alineación del prompt consistió en diseñar, evaluar y refinar iterativamente las instrucciones proporcionadas al LLM para clasificar preguntas del SOCE como acusatorias

o no acusatorias. Para ello, se utilizó el modelo gpt-5-mini con configuración thinking effort high. El prompt fue construido con definiciones conceptuales, reglas de decisión y ejemplos representativos de ambas clases.

La alineación del prompt tuvo como objetivo reducir la ambigüedad entre dos tipos de lenguaje que suelen aparecer en contratación pública: por un lado, preguntas críticas, técnicas o normativas que solicitan aclaraciones, modificaciones o correcciones; y por otro lado, preguntas que atribuyen explícitamente una conducta indebida, direccionamiento, favoritismo, manipulación o ilegalidad a la entidad contratante o al proceso. Esta distinción fue central, ya que muchos falsos positivos iniciales provenían de preguntas que cuestionaban requisitos restrictivos o citaban normas, pero sin formular una acusación directa de irregularidad.

Cada versión del prompt fue aplicada sobre el subconjunto de validación. Las predicciones del LLM fueron comparadas con las etiquetas humanas originales mediante métricas como precision, recall, F1-score, accuracy y matriz de confusión. Dado el desbalance de clases, la evaluación no se basó únicamente en la exactitud global, sino especialmente en el comportamiento de la clase minoritaria acusatoria. En particular, se buscó un balance entre sensibilidad y precisión: un prompt excesivamente sensible podía detectar la mayoría de preguntas acusatorias, pero generar demasiados falsos positivos; mientras que un prompt demasiado estricto podía reducir falsos positivos, pero dejar pasar preguntas realmente acusatorias.

A partir de este proceso iterativo, se seleccionó como versión final el prompt que presentó el balance más adecuado entre precision, recall y F1-score para la clase acusatoria, manteniendo además un comportamiento estable en la salida esperada. Una vez seleccionado el prompt final, este fue congelado; es decir, no se realizaron modificaciones adicionales antes de aplicarlo sobre el conjunto de test depurado y sobre las preguntas de los procesos de 2021. Esta decisión permitió evitar un ajuste excesivo del prompt al conjunto de evaluación.

Control de leakage y subconjunto depurado.

Una consideración metodológica adicional fue el posible solapamiento entre el conjunto de test inicial y los datos utilizados previamente para entrenar los modelos clásicos empleados en la construcción de los índices. Dado que el dataset original de 5005 preguntas había sido

utilizado parcialmente en el entrenamiento de modelos supervisados de Roh (2024), evaluar directamente los modelos clásicos sobre todo el conjunto de test inicial podía introducir data leakage.

Este problema es relevante porque, si un modelo fue entrenado con observaciones que luego aparecen en el conjunto de evaluación, sus métricas pueden verse artificialmente favorecidas. En ese caso, la comparación entre modelos clásicos, etiquetas humanas y clasificaciones del LLM no sería completamente independiente. Para mitigar este riesgo, se realizó una depuración adicional del conjunto de test inicial.

El procedimiento consistió en identificar y excluir del conjunto de test aquellas preguntas que también aparecían en los conjuntos de entrenamiento utilizados por los modelos clásicos. La identificación del solapamiento se realizó a nivel de pregunta, tomando como referencia la coincidencia de observaciones entre los archivos de entrenamiento y el conjunto de test inicial. El resultado fue un subconjunto de test depurado, compuesto únicamente por preguntas que no habían sido utilizadas previamente para entrenar los modelos clásicos.

Este subconjunto depurado fue utilizado para realizar una comparación más independiente entre tres fuentes: las etiquetas humanas originales, las clasificaciones generadas por el LLM y las salidas de los modelos supervisados utilizados para construir los índices. De esta manera, el análisis evitó favorecer a los modelos clásicos por exposición previa a los datos y permitió evaluar con mayor validez la consistencia relativa entre las distintas fuentes de clasificación.

Construcción de la densidad LLM a nivel de proceso.

Aunque la alineación del prompt y su evaluación inicial se realizaron a nivel de pregunta, el objetivo principal de esta tesis es construir índices de riesgo a nivel de proceso contractual. Por ello, fue necesario extender el uso del LLM desde la clasificación individual de preguntas hacia una medida agregada por proceso.

Esta transición era necesaria porque el dataset original etiquetado no contenía necesariamente todas las preguntas asociadas a cada proceso de contratación. En consecuencia, aunque era útil para entrenar y evaluar clasificadores a nivel de pregunta, no permitía calcular directamente un índice completo y consistente a nivel de proceso. Para resolver esta

limitación, se seleccionó una muestra aleatoria de procesos correspondientes al año 2021 y se recopilaron todas las preguntas asociadas a dichos procesos.

Luego, el prompt final fue aplicado a cada pregunta de estos procesos, clasificándola como acusatoria o no acusatoria. A partir de estas clasificaciones, se calculó una densidad acusatoria por proceso, definida como la proporción de preguntas clasificadas como acusatorias por el LLM respecto del total de preguntas del proceso.

Esta medida permitió convertir las decisiones del LLM a nivel de pregunta en una señal agregada a nivel de proceso. La densidad LLM no se interpreta como una etiqueta definitiva de riesgo ni como evidencia de corrupción, sino como una referencia semántica complementaria para comparar el comportamiento de los índices construidos. En particular, esta señal fue utilizada posteriormente para evaluar la cercanía distribucional, el ordenamiento relativo y la coincidencia binaria entre los índices y el criterio semántico del LLM.

La construcción de esta densidad permitió conectar el problema original de clasificación textual con el objetivo central de la tesis: priorizar procesos de contratación pública según señales lingüísticas de posible riesgo. Así, el LLM funcionó como un puente metodológico entre el nivel individual de pregunta y el nivel agregado de proceso, permitiendo evaluar si los índices propuestos capturan patrones similares a los identificados por una lectura semántica automatizada.

Resultados

Resultados de la selección de modelos.

Roh (2024) contaba con un archivo de resumen de métricas e información relevante (como dataset de entrenamiento, embeddings utilizados, entre otros) acerca de cada modelo que entrenó. Al aplicar los filtros para encontrar modelos que cumplan con los perfiles mencionados en los criterios de selección, eligieron los siguientes modelos.

Perfil 1: Alta Sensibilidad

Campo	Valor
Modelo	Random Forest
Representación de texto	text-embedding-3-large
Dataset	Consolidated Data Augmentation
Recall	0.9655
Precision	0.1555
F1-Score	0.2679
AUC-ROC	0.96
Matriz de confusión	TP --28 --- FP 152 --- FN 1 --- TN 820
Hiperparámetros	max_depth=None, min_samples_leaf=1, n_estimators=200

Tabla 2. Características del primer perfil de modelo seleccionado

Inicialmente, las métricas del trabajo de Roh (2024) sugerían a Naive Bayes como candidato para este perfil (FN = 0). No obstante, durante la fase experimental orientada a la construcción del índice continuo, se observó que la aplicación de este modelo sobre embeddings de alta dimensionalidad (3072 dimensiones fuertemente correlacionadas) viola el supuesto de independencia condicional en este algoritmo. Esto generó distribuciones de probabilidad extremas (tendían a 0 o a 1), arruinando la calibración requerida para el índice. Dado este hallazgo, el modelo de Naive Bayes fue descartado.

Las métricas obtenidas al reproducir el modelo fueron las siguientes:

Campo	Valor
Recall	0.9310
Precision	0.1492
F1-Score	0.2571
Matriz de confusión	TP: 27 — FP: 154 — FN: 2 — TN: 818
Hiperparámetros	max_depth=None, min_samples_leaf=1, n_estimators=200, random_state=42, n_jobs=1

Tabla 3. Métricas obtenidas en la reproducción del primer perfil de modelo seleccionado

Los hiperparámetros de random_state y n_jobs fueron añadidos para reproducibilidad porque no fueron encontrados en la documentación de Roh (2024). Estas métricas difieren con las

obtenidas originalmente. Esto se debe a que para este perfil no se tenía el valor del parámetro `random_state`. Por ende, no se pudo replicar enteramente este modelo, aunque se obtienen métricas muy parecidas.

Perfil 2: Alta Precisión

Campo	Valor
Modelo	Random Forest Classifier
Representación de texto	text-embedding-3-large
Dataset	Balanced 4
Recall	0.5517
Precision	0.7619
F1-Score	0.6400
AUC-ROC	0.94
Matriz de confusión	TP -- 16 --- FP 5 --- FN 13 --- TN 967
Hiperparámetros	max_depth=None, min_samples_leaf=1, n_estimators=200, random_state=42, n_jobs=1

Tabla 4. Características del segundo perfil de modelo seleccionado

Este modelo genera únicamente cinco falsos positivos en el conjunto de prueba, alcanzando una precisión superior al 76%. Estas fueron las métricas obtenidas al reproducir el modelo:

Campo	Valor
Recall	0.51724
Precision	0.78947
F1-Score	0.62500
Matriz de confusión	TP: 15 — FP: 4 — FN: 14 — TN: 968
Hiperparámetros	max_depth=None, min_samples_leaf=1, n_estimators=200, random_state=42, n_jobs=1

Tabla 5. Métricas obtenidas en la reproducción del segundo perfil de modelo seleccionado

Al replicar el modelo, se identificaron variaciones en la distribución de la matriz de confusión respecto al reporte original. Específicamente, se registró un decremento en uno tanto en los verdaderos positivos (TP) como en los falsos positivos (FP), el cual también implicó un

incremento equivalente en las categorías de falsos negativos (FN) y verdaderos negativos (TN). De cierta manera, esta variación resultó favorable, ya que el modelo está orientado específicamente a la minimización de falsos positivos. En consecuencia, el ajuste observado es congruente con su perfil operativo y refuerza su propósito funcional.

Perfil 3: Equilibrado

Campo	Valor
Modelo	Logistic Regression
Representación de texto	text-embedding-3-large
Dataset	Balanced 4
Recall	0.7586
Precision	0.6111
F1-Score	0.6769
AUC-ROC	0.94
Matriz de confusión	TP -- 22 --- FP 14 --- FN 7 --- TN 958
Hiperparámetros	C = 100, penalty = 'l2', solver = 'saga', max_iter = 1000

Tabla 6. Características del tercer perfil de modelo seleccionado

Este modelo presenta el mayor F1-Score dentro del conjunto equilibrado, manteniendo una tasa de falsos positivos moderada y un equilibrio razonable entre cobertura y confiabilidad. A continuación, se muestran las medidas obtenidas en la reproducción de este modelo. A continuación, se presenta lo obtenido en la reproducción del modelo:

Campo	Valor
Recall	0.75862
Precision	0.64706
F1-Score	0.69841
Matriz de confusión	TP: 22— FP: 12 — FN: 7 — TN: 960
Hiperparámetros	C = 100, penalty = 'l2', solver = 'saga', max_iter = 1000

Tabla 7. Métricas obtenidas en la reproducción del segundo perfil de modelo seleccionado

La reproducción del modelo de Regresión Logística reflejó una consistencia notable, manteniendo un Recall invariable de 0.7586 (22 verdaderos positivos y 7 falsos negativos). La diferencia más significativa se presentó en la reducción de dos falsos positivos (pasando de 14 a 12), los cuales fueron correctamente reclasificados como verdaderos negativos, aumentando esta cifra de 958 a 960. Esta ligera mejora en la especificidad del modelo resultó en un incremento de la precisión, que subió de 0.6111 a 0.6470, y un F1-Score más sólido de 0.6984, lo que valida la robustez del modelo respecto a la clasificación de la clase negativa.

Índices comparados contra “LLM as a judge”.

Primero, se reporta el proceso de alineación del prompt a nivel de pregunta. Luego, se evalúa el desempeño del prompt seleccionado frente a etiquetas humanas en un subconjunto independiente. Finalmente, se utiliza el LLM para clasificar preguntas completas de 400 procesos de 2021 y comparar la señal agregada resultante con los índices desarrollados. Es importante señalar que las clasificaciones del LLM no se interpretan como una verdad de referencia definitiva, sino como una señal semántica complementaria. Por tanto, las comparaciones posteriores no buscan demostrar qué índice es “correcto” en sentido absoluto, sino evaluar qué índice presenta mayor consistencia relativa con el criterio semántico aprendido por el LLM.

Se realizaron varios experimentos durante esta sección del proyecto. Primero, se realizó un procedimiento llamado “alineación del prompt”, en el que se utilizó el modelo gpt-5-mini con thinking effort high. Para ello, la base fue un dataset de 5005 preguntas ya etiquetadas como acusatorias o no acusatorias. Se realizaron varias divisiones del dataset original, las cuales respondieron a la necesidad de mantener separadas las distintas etapas del proceso de alineación y evaluación del prompt.

En primer lugar, se reservó un conjunto de test independiente, equivalente al 20% de todo el dataset original, con el objetivo de contar con una muestra no utilizada durante el diseño del prompt y poder evaluar su desempeño final sin sesgo por ajustes previos. Esta separación es importante porque, si el mismo conjunto se utilizara tanto para modificar el prompt como para evaluarlo, las métricas finales podrían sobreestimar la capacidad real del LLM para generalizar a nuevas preguntas. Otro aspecto importante es que se realizó un muestreo

aleatorio estratificado, lo que significa que la proporción de las clases o características clave se mantuvo constante en ambos conjuntos. Este conjunto de prueba terminó con una proporción aproximada de 97% de la clase no acusatoria y 3% de la clase acusatoria. El otro conjunto independiente fue el conjunto de “entrenamiento”, correspondiente al 80% del conjunto total. De igual manera, este mantuvo la proporción aproximada de 97% y 3% para las clases negativa y positiva respectivamente.

A su vez, el conjunto de “entrenamiento” fue dividido en dos subconjuntos con funciones distintas, en la proporción 80%-20%. El primero se utilizó como fuente para seleccionar ejemplos de preguntas acusatorias y no acusatorias que fueron incorporados dentro del prompt. Estos ejemplos funcionaron como guía semántica para orientar al modelo sobre la frontera conceptual entre ambas clases. Sin embargo, para evitar que el desempeño del prompt se midiera sobre las mismas observaciones usadas como ejemplos, se separó un segundo subconjunto de validación. Este conjunto permitió evaluar si el prompt, una vez definido, lograba generalizar correctamente a preguntas no incluidas en sus ejemplos. Igualmente, cada conjunto aproximadamente mantuvo las mismas proporciones antes mencionadas.

Es importante señalar que ambos subconjuntos del conjunto de entrenamiento fueron utilizados únicamente para alinear el prompt lo más cercano posible a la etiqueta humana. Es decir, solamente sería utilizado por el llm. Sin embargo, el conjunto de test inicialmente definido (1001 observaciones) cumplía un doble propósito metodológico. Por un lado, se utilizó para evaluar el desempeño del LLM como clasificador de preguntas acusatorias frente a las etiquetas humanas. Por otro, también fue empleado como base de comparación entre las clasificaciones generadas por el LLM y los índices desarrollados previamente (ID_prob_lr, ID_prob_weighted e ID_bin_rf).

Una consideración metodológica relevante es que el dataset original de 5005 preguntas también había sido utilizado parcialmente durante el entrenamiento de los modelos clásicos empleados para construir dichos índices. En consecuencia, utilizar la totalidad del conjunto de test de 1001 observaciones para comparar directamente estos modelos contra el LLM podía introducir o data leakage entre entrenamiento y evaluación, favoreciendo artificialmente a los modelos que ya habían visto parte de esos datos durante etapas previas.

Para mitigar este problema, se realizó una depuración adicional del conjunto de test, restringiendo la comparación final a un subconjunto de 223 preguntas que no habían sido utilizadas previamente en el entrenamiento de los modelos clásicos. En otras palabras, el conjunto de test pasó de 1001 observaciones a 223, puesto que 778 preguntas se utilizaban para el entrenamiento de los modelos que calculaban los índices. De esta manera, el subconjunto reducido funcionó como un espacio de comparación más independiente entre tres elementos distintos: (1) las etiquetas humanas originales, (2) las clasificaciones generadas por el LLM y (3) los índices probabilísticos y binarios contruidos a partir de modelos supervisados.

A continuación, se muestra una tabla resumiendo estas divisiones que se realizaron:

Conjunto	Tamaño	Porcentaje respecto al dataset original	Proporción de clases (0-1)	Propósito
Dataset original etiquetado	5005	100%	0.9706-0.0294	Base completa de preguntas etiquetadas manualmente como acusatorias o no acusatorias
Conjunto de entrenamiento inicial	4004	80%	0.9705-0.0295	Utilizado para el proceso de alineación del prompt y selección de ejemplos
Conjunto de test inicial	1001	20%	0.9710-0.0290	Reservado inicialmente para la evaluación final del LLM y comparación con los índices desarrollados
Subconjunto para ejemplos del prompt	3203	64% del total (80% del conjunto de entrenamiento)	0.9707-0.0293	Utilizado para seleccionar ejemplos acusatorios y no acusatorios incluidos dentro del prompt
Subconjunto de validación del prompt	801	16% del total (20% del conjunto de entrenamiento)	0.9700-0.0300	Utilizado para validar el desempeño del prompt antes de la evaluación final
Subconjunto de test depurado para comparación final	223	4.46%	0.9817-0.0183	Utilizado para la comparación final entre etiquetas humanas, clasificaciones del LLM e índices, excluyendo observaciones previamente utilizadas en el entrenamiento de los modelos clásicos

Tabla 8. Distribución de conjuntos utilizados para la alineación, validación, y test del prompt

A partir de estas separaciones del dataset, se llevó a cabo el procedimiento de “alinear el prompt”. Este proceso consistió en diseñar y refinar iterativamente un prompt para el modelo gpt-5-mini utilizando la configuración *thinking effort high*. El prompt incluía definiciones conceptuales, reglas de clasificación, y ejemplos de preguntas acusatorias y no acusatorias en el contexto de contratación pública, con el objetivo de orientar al modelo respecto a la frontera semántica entre ambas categorías.

Posteriormente, el prompt era aplicado sobre las preguntas pertenecientes al “Subconjunto de validación del prompt”, solicitando al modelo clasificar cada observación como acusatoria o no acusatoria. Las predicciones obtenidas fueron comparadas con las etiquetas humanas originales, permitiendo evaluar el desempeño del prompt mediante métricas como precision, recall, F1-score y accuracy.

A lo largo de este proceso se evaluaron un total de 15 versiones distintas del prompt. Cada iteración incorporó ajustes en las definiciones, reglas o ejemplos utilizados, buscando reducir falsos positivos y mejorar la separación conceptual entre críticas técnicas o normativas y acusaciones explícitas de irregularidad. Finalmente, se seleccionó el prompt que presentó el balance más adecuado entre *recall*, *precision*, *F1-score* y desempeño general frente a las etiquetas humanas.

A continuación, se presentan las métricas obtenidas por cada una de las versiones evaluadas del prompt con respecto a la clasificación humana de referencia:

Prompt	Precision	Recall	F1 Score	Accuracy	TN	TP	FN	FP
1	0.26	0.89	0.4	0.94	368	8	1	23
2	0.3438	0.9167	0.5	0.94	367	11	1	21
3	0.45	0.75	0.5625	0.96	377	9	3	11
4	0.6429	0.75	0.6923	0.98	383	9	3	5
5	0.6207	0.75	0.6792	0.98	766	18	6	11
6	0.8235	0.5833	0.6829	0.98	774	14	10	3
7	0.6	0.75	0.6667	0.98	765	18	6	12
8	0.4	0.9167	0.557	0.96	744	22	2	33
9	0.5714	0.8333	0.678	0.98	762	20	4	15
10	0.4286	0.875	0.5753	0.96	749	21	3	28
11	0.38	0.8636	0.5278	0.96	738	19	3	31
12	0.4773	0.875	0.6176	0.97	754	21	3	23

13	0.28	1	0.43	0.92	714	24	0	63
14	0.1316	0.8333	0.2273	0.83	645	20	4	132
15	0.8276	1	0.9057	0.99	772	24	0	5

Tabla 9. Métricas de desempeño de las distintas versiones del prompt

Los resultados muestran que el Prompt 15 alcanza el desempeño más sólido entre todas las versiones evaluadas, ya que no solo obtiene métricas elevadas, sino que además mantiene un balance adecuado entre *accuracy*, *precision*, *recall* y *F1-score*. Este comportamiento resulta especialmente relevante en un contexto de fuerte desbalance de clases, donde optimizar una métrica de manera aislada puede deteriorar significativamente las demás.

Una vez seleccionado el prompt final, se procedió a utilizar el “Subconjunto de test depurado para comparación final”. Sobre este conjunto, el LLM volvió a clasificar las preguntas como acusatorias o no acusatorias utilizando el Prompt 15 ya definido, sin realizar modificaciones adicionales. Posteriormente, las predicciones generadas fueron comparadas nuevamente con las etiquetas humanas originales, con el objetivo de verificar que el desempeño observado durante la etapa de validación se mantuviera relativamente estable en un conjunto independiente de evaluación.

Los resultados obtenidos fueron los siguientes:

Prompt	Precision	Recall	F1 Score	Accuracy	TN	TP	FN	FP
15	0.8333	0.8333	0.8333	0.9910	216	5	1	1

Tabla 10. Resultados finales del Prompt 15 sobre el subconjunto de test depurado

Los resultados obtenidos sobre el “Subconjunto de test depurado para comparación final” muestran que el Prompt 15 mantuvo un desempeño alto y relativamente balanceado en todas las métricas principales. En particular, alcanzó valores de *precision*, *recall* y *F1-score* de 0.8333, lo que indica una capacidad consistente tanto para identificar correctamente preguntas acusatorias como para evitar clasificaciones positivas incorrectas. Asimismo, la *accuracy* global alcanzó un valor de 0.9910.

La matriz de confusión muestra que el modelo clasificó correctamente 216 preguntas no acusatorias y 5 preguntas acusatorias, generando únicamente un falso positivo y un falso

negativo. Estos resultados sugieren que el prompt logró conservar un equilibrio adecuado entre sensibilidad y precisión incluso en un conjunto independiente de evaluación.

No obstante, estos resultados deben interpretarse con cautela debido al tamaño reducido y al fuerte desbalance del subconjunto utilizado. La clase acusatoria continúa representando una proporción muy pequeña de las observaciones, por lo que pequeñas variaciones en el número de errores pueden producir cambios importantes en las métricas. En este sentido, los resultados no deben entenderse como una validación definitiva del modelo, sino como evidencia de que el Prompt 15 mantiene un comportamiento relativamente estable y consistente en relación a las etiquetas humanas, fuera de la etapa de alineación.

Adicionalmente, y con un fin meramente exploratorio, se realizó una comparación a nivel de pregunta entre los índices, las clasificaciones del LLM y la etiqueta humana original, permitiendo así obtener una primera aproximación sobre qué modelos presentaban un comportamiento más cercano a ambas referencias. Cabe destacar que esta comparación se reporta exclusivamente como una verificación complementaria y no como un criterio de selección de los índices. Para el caso de los modelos con probabilidad, el umbral que se seleccionó fue de 0.5, puesto que es el corte por defecto. A continuación, se muestran estos resultados:

Modelo	Es binario	F1 vs LLM	Precision vs LLM	Recall vs LLM	Average Precision vs LLM	ROC-AUC vs LLM
ID_prob_weighted	No	0.615385	0.571429	0.666667	0.686141	0.976959
ID_bin_lr	Sí	0.615385	0.571429	0.666667	0.389921	0.826421
ID_prob_rf	No	0.545455	0.600000	0.500000	0.627778	0.971198
ID_bin_rf	Sí	0.545455	0.600000	0.500000	0.313453	0.745392
ID_prob_rf_aug	No	0.243902	0.142857	0.833333	0.536637	0.876344
ID_bin_rf_aug	Sí	0.243902	0.142857	0.833333	0.123532	0.847542
ID_prob_lr	No	0.142857	0.125000	0.166667	0.064767	0.612903

Tabla 11. Comparación de los modelos frente al LLM

Modelo	Es binario	F1 vs Humano	Precision vs Humano	Recall vs Humano	Average Precision vs Humano	ROC-AUC vs Humano
ID_prob_weighted	No	0.769231	0.714286	0.833333	0.878788	0.987711
ID_bin_lr	Sí	0.769231	0.714286	0.833333	0.599722	0.912058
ID_prob_rf	No	0.727273	0.800000	0.666667	0.827778	0.989247
ID_bin_rf	Sí	0.727273	0.800000	0.666667	0.542302	0.831029
ID_prob_rf_aug	No	0.292683	0.171429	1.000.000	0.823465	0.988479
ID_bin_rf_aug	Sí	0.292683	0.171429	1.000.000	0.171429	0.933180
ID_prob_lr	No	0.142857	0.125000	0.166667	0.075181	0.698925

Tabla 12. Comparación de los modelos frente a la etiqueta humana

La tabla 11 presenta la comparación de los modelos frente a las clasificaciones generadas por el LLM en el subconjunto de test depurado. Los resultados muestran que ID_prob_weighted e ID_bin_lr obtienen el mejor desempeño frente al LLM, ambos con un F1-score de 0.6154, precision de 0.5714 y recall de 0.6667. Entre los modelos probabilísticos, ID_prob_weighted destaca además por alcanzar el mayor average precision y un ROC-AUC elevado, lo que sugiere una buena capacidad de ordenamiento respecto al criterio del LLM. En contraste, ID_prob_lr presenta el desempeño más bajo en esta comparación, con valores reducidos de F1, precision y recall.

La tabla 12 muestra la comparación de los modelos frente a la etiqueta humana original. En este caso, nuevamente ID_prob_weighted e ID_bin_lr presentan los mejores valores de F1-score, precision y recall, alcanzando un F1 de 0.7692. También se observa que ID_prob_rf e ID_bin_rf mantienen un desempeño competitivo, con mayor precision pero menor recall. Los modelos aumentados, especialmente ID_prob_rf_aug e ID_bin_rf_aug, alcanzan recall perfecto frente a la etiqueta humana, pero con baja precision, lo que indica una tendencia a clasificar demasiadas preguntas como acusatorias. En conjunto, ambas tablas sugieren que ID_prob_weighted es uno de los modelos más consistentes, ya que mantiene un buen desempeño tanto frente al LLM como frente a la etiqueta humana.

Para esta comparación se utilizó el “Subconjunto de test depurado para comparación final”. Esta decisión respondió a una consideración metodológica importante: los conjuntos de entrenamiento utilizados por los modelos clásicos para calcular los distintos índices

contenían varias observaciones que también formaban parte del “Conjunto de test inicial”. Por lo tanto, utilizar directamente ese conjunto completo podía introducir *data leakage*, favoreciendo artificialmente el desempeño de los modelos clásicos al evaluarlos sobre preguntas que ya habían sido vistas durante su entrenamiento.

Para evitar esta contaminación entre entrenamiento y evaluación, se eliminaron del “Conjunto de test inicial” todas las muestras que también aparecían en los conjuntos de entrenamiento de los modelos. De esta manera, el subconjunto depurado permitió realizar una comparación más independiente entre tres fuentes de clasificación: la etiqueta humana, el LLM y los modelos supervisados utilizados para construir los índices.

Como fue mencionado anteriormente, estos resultados iniciales corresponden únicamente al nivel de pregunta. Sin embargo, el objetivo final de esta investigación no era clasificar preguntas de manera aislada, sino construir un índice de riesgo a nivel de proceso de contratación. Precisamente, una de las funciones del esquema de *LLMs as a judge* fue facilitar esta transición entre el nivel individual de pregunta y el nivel agregado de proceso.

Esta transición era necesaria porque el dataset original etiquetado no contenía la totalidad de preguntas asociadas a cada proceso. En otras palabras, muchos procesos estaban incompletos desde el punto de vista documental, ya que solo se disponía de algunas de sus preguntas y no de la conversación completa dentro del procedimiento de contratación. Como consecuencia, el dataset original no era suficiente para calcular directamente índices consistentes a nivel de proceso.

Para abordar este problema, se seleccionaron aleatoriamente 400 procesos correspondientes al año 2021, obteniendo un total de 3183 preguntas asociadas a dichos procesos. Posteriormente, se utilizó el LLM con el Prompt 15 para clasificar cada pregunta como acusatoria o no acusatoria. A partir de estas clasificaciones, se construyó un índice referencial a nivel de proceso basado en la densidad de preguntas acusatorias dentro de cada proceso. Este índice permitió generar una medida agregada de riesgo que posteriormente fue utilizada para comparar el comportamiento de los distintos índices desarrollados en la investigación.

A continuación, se resumen las características de esta muestra:

Elemento	Valor
Procesos seleccionados	400
Año	2021
Preguntas totales	3183
Promedio de preguntas por proceso	7.96
Índice LLM calculado	Densidad de preguntas acusatorias
Prompt utilizado	Prompt 15

Tabla 13. Características de la muestra de procesos utilizada para la evaluación con LLM

Se compararon los valores generados por el LLM con los índices a nivel de proceso obtenidos a partir de los siete modelos evaluados: ID_bin_rf, ID_bin_rf_aug, ID_bin_lr, ID_prob_rf, ID_prob_rf_aug, ID_prob_lr e ID_prob_weighted. El objetivo de esta comparación fue analizar qué tan cercanos eran los índices construidos respecto a la señal semántica producida por el LLM, utilizado como referencia complementaria de evaluación.

La comparación se realizó en tres niveles. En primer lugar, se analizó la forma de las distribuciones, con el fin de observar si los índices producían valores con patrones similares a los del LLM. En segundo lugar, se evaluó el ordenamiento de los procesos, es decir, si los modelos tendían a ubicar en posiciones similares a los procesos con mayor o menor nivel de riesgo. Finalmente, se consideró la coincidencia en la priorización de procesos mediante medidas de solapamiento en los grupos con puntajes más altos.

Para el primer nivel de comparación se utilizaron métricas orientadas a evaluar la similitud entre la distribución de valores generada por el LLM y las distribuciones producidas por cada índice. Se calculó la distancia de Kolmogorov-Smirnov (KS), junto con su valor estadístico asociado, para medir la mayor diferencia entre las distribuciones acumuladas. También se utilizó la distancia de Wasserstein, que permite cuantificar qué tan distante se encuentra una distribución de otra en términos del “desplazamiento” necesario para hacerlas coincidir.

Adicionalmente, se incorporó la divergencia de Jensen-Shannon (JS) como una medida de diferencia entre distribuciones de probabilidad. Finalmente, se compararon la diferencia de medias y la diferencia de desviaciones estándar, con el fin de observar si los índices presentaban niveles promedio y grados de dispersión similares a los del LLM. En conjunto, estas métricas permiten evaluar si los índices no solo producen valores dentro del mismo rango, sino también si reproducen una forma distribucional similar a la señal generada por el LLM. A continuación, se presentan los resultados obtenidos para cada modelo respecto al LLM:

Modelo	DistanciaKS	Valor KS	Wasserstein	Divergencia JS	Diff Media	Diff Std
ID_bin_rf	0.8200	6.78e-136	0.0026	0.0030	0.0035	- 0.0011
ID_bin_lr	0.8200	6.78e-136	0.0556	0.8801	0.0000	- 0.0350
ID_prob_rf	0.4100	1.82e-30	0.1684	0.7020	0.0000	0.0954
ID_prob_lr	0.4100	1.82e-30	0.1684	0.7074	0.0000	0.0954
ID_prob_weighted	0.4100	1.82e-30	0.1684	0.7079	0.0000	0.0954
ID_prob_rf_aug	0.4100	1.82e-30	0.1684	0.7079	0.0000	0.0954
ID_bin_rf_aug	0.4075	4.33e-30	0.1720	0.7906	0.0000	0.0930

Tabla 14. Métricas de similitud distribucional entre los índices por proceso y el LLM

En términos distribucionales, ID_bin_rf presenta la menor distancia de Wasserstein y la menor divergencia Jensen-Shannon frente al LLM, mientras que ID_bin_rf_aug obtiene la menor distancia KS.

Además de las métricas cuantitativas, se compararon visualmente las distribuciones generadas por el LLM, Kapak y los distintos índices calculados a nivel de proceso. El objetivo de estos gráficos fue observar el comportamiento global de cada método, considerando tanto los valores asignados por cada índice como la proporción de procesos que se concentraba en determinados rangos de puntaje. Para ello, se utilizaron dos tipos de

visualizaciones: histogramas y curvas de densidad KDE, tanto individuales como superpuestas.

En los histogramas, el eje X representa el porcentaje de preguntas acusatorias por proceso, agrupado en 20 intervalos (bins). Para Kapak y el LLM, este valor corresponde a una densidad calculada como el número de preguntas clasificadas como acusatorias dividido para el total de preguntas del proceso. Para los índices binarios (ID_bin_), el valor también puede interpretarse como una densidad de decisiones positivas agregadas a nivel de proceso. En cambio, para los índices probabilísticos (ID_prob_), el valor representa una probabilidad agregada por proceso; aunque no corresponde estrictamente a una densidad de preguntas acusatorias, se grafica en la misma escala porque sus valores también se encuentran en el rango [0,1]. El eje Y muestra el porcentaje de procesos ubicados dentro de cada rango de puntaje, por lo que permite identificar qué proporción de los 400 procesos analizados se concentra en valores bajos, medios o altos.

En cada histograma se comparó la distribución generada por el LLM con la distribución correspondiente a cada índice. Esto permitió observar visualmente qué tan similares eran sus patrones de asignación de riesgo a nivel de proceso. A continuación, se presentan dos ejemplos de estas distribuciones comparadas, correspondientes a ID_bin_lr e ID_prob_rf frente al LLM.




Figura 1. Distribución comparada de proporción de preguntas acusatorias por proceso entre LLM e ID_bin_lr




Figura 2. Distribución comparada de proporción de preguntas acusatorias por proceso entre LLM e ID_prob_rf

Estas dos distribuciones corresponden a los dos enfoques principales utilizados para el cálculo de los índices: el enfoque basado en densidad de preguntas acusatorias y el enfoque basado en probabilidades directas generadas por los modelos.

Adicionalmente, se utilizaron curvas KDE (Kernel Density Estimation) para representar las distribuciones de manera suavizada. A diferencia del histograma, que agrupa los valores en barras discretas, la KDE estima una curva continua que muestra en qué zonas del rango $[0,1]$ se concentran más procesos. En estos gráficos, el eje X mantiene la misma interpretación: representa el valor agregado por proceso, ya sea como densidad de preguntas acusatorias o como probabilidad promedio. El eje Y, en cambio, representa la densidad estimada de la distribución, no el porcentaje directo de procesos. Por esta razón, sus valores pueden superar 1, ya que lo que se normaliza en una densidad no es la altura de la curva, sino el área total bajo ella.

Las curvas KDE individuales permiten observar la forma general de cada distribución: si la mayoría de procesos se concentra cerca de cero, si existe una cola hacia valores altos o si el índice tiende a desplazar más procesos hacia niveles intermedios o altos de riesgo. Por su parte, las curvas KDE superpuestas permiten comparar directamente el comportamiento del LLM, Kapak y los índices en una misma figura. Una curva más cercana a la del LLM sugiere mayor similitud visual con la señal semántica generada por este modelo, mientras que una curva más cercana a Kapak indica mayor continuidad con la línea base histórica. Sin embargo, estas visualizaciones deben interpretarse como herramientas exploratorias, ya que

la similitud visual de las distribuciones no garantiza que los mismos procesos sean priorizados por cada método. Por ello, estos gráficos se complementan con métricas formales de similitud distribucional, correlación y solapamiento en los procesos de mayor puntaje. A continuación, se muestran los gráficos individuales de cada índice comparado con el LLM:




Figura 3. Curvas KDE individuales de cada índice frente al LLM

Los gráficos presentan las distribuciones KDE de Kapak, del LLM y de los distintos índices calculados sobre los 400 procesos aleatorios de 2021. Se muestra cada distribución por separado, lo que permite observar con mayor claridad la forma individual de cada índice, su concentración principal y la ubicación de su media. En general, Kapak, el LLM, ID_bin_rf, ID_bin_lr e ID_prob_lr presentan una fuerte concentración cerca de cero, lo que indica que la mayoría de procesos tienen una baja proporción de preguntas acusatorias o puntajes bajos de riesgo. En cambio, ID_prob_rf, ID_prob_weighted e especialmente ID_prob_rf_aug muestran distribuciones desplazadas hacia valores más altos, lo que sugiere una tendencia a asignar puntajes más elevados a una mayor proporción de procesos.

A continuación, se muestran los resultados del gráfico con todos los índices incluidos:




Figura 4. Curvas KDE superpuestas de cada índice frente al LLM

Este gráfico superpone todas las curvas KDE en una misma visualización, facilitando la comparación directa entre los métodos. Allí se observa que el LLM y Kapak tienen distribuciones concentradas en valores bajos, mientras que algunos índices probabilísticos se alejan de ese patrón y presentan mayor masa en rangos intermedios. En particular, ID_prob_rf_aug se ubica claramente hacia valores cercanos a 0.5, lo que sugiere un comportamiento más permisivo o una mayor tendencia a marcar procesos con riesgo. Por su parte, ID_prob_weighted se concentra alrededor de valores intermedios-bajos, mostrando un comportamiento menos extremo que ID_prob_rf_aug, pero más desplazado hacia la derecha que el LLM. En conjunto, estos gráficos permiten identificar visualmente qué índices son más conservadores, cuáles asignan puntajes más altos y cuáles presentan una forma más cercana a la distribución del LLM.

Para el segundo nivel de comparación se evaluó la similitud en el ordenamiento de los procesos entre cada índice y la señal agregada generada por el LLM. A diferencia de la comparación distribucional, que analiza la forma general de los puntajes, este análisis busca determinar si los índices tienden a priorizar los procesos en un orden similar al del LLM. Esto es especialmente relevante porque el objetivo práctico del índice no es únicamente asignar un valor numérico, sino permitir la jerarquización de procesos según su nivel de riesgo textual.

Para ello, se utilizaron tres métricas de correlación: Spearman, Kendall y Pearson. La correlación de Spearman permite evaluar si existe una relación monotónica entre el ranking producido por cada índice y el ranking generado por el LLM; Kendall mide la concordancia entre pares de procesos ordenados; y Pearson mide la relación lineal entre los valores asignados por ambos métodos. Además, se incorporó el Top-k overlap en los cortes Top 10, Top 20, Top 50 y Top 100, con el fin de identificar qué proporción de los procesos con mayor puntaje según el LLM también aparece entre los procesos priorizados por cada índice.

Modelo	Spearman	Kendall	Pearson	Top 10	Top 20	Top 50	Top 100
ID_bin_lr	0.7879	0.7731	0.9553	90%	85%	72%	72%
ID_bin_rf	0.7292	0.7050	0.7333	60%	60%	68%	79%
ID_prob_lr	0.5314	0.4377	0.9374	80%	75%	74%	57%
ID_prob_weighted	0.4355	0.3538	0.8747	80%	70%	68%	51%
ID_prob_rf	0.3590	0.2899	0.6194	50%	50%	52%	44%
ID_prob_aug	0.2821	0.2236	0.5146	60%	40%	50%	44%
ID_bin_aug	0.2295	0.1924	0.2861	0%	5%	18%	37%

Tabla 15. Correlación y solapamiento entre los índices por proceso y el LLM

Los resultados muestran que ID_bin_lr presenta la mayor alineación con el LLM en términos de ordenamiento, alcanzando los valores más altos en Spearman, Kendall y Pearson. Además, obtiene el mayor solapamiento en los cortes Top 10 y Top 20, con coincidencias del 90% y 85%, respectivamente. Esto sugiere que este índice no solo se relaciona fuertemente con los valores asignados por el LLM, sino que también tiende a priorizar los mismos procesos en los niveles más altos de riesgo.

Por su parte, ID_bin_rf también muestra un desempeño sólido, especialmente en el Top 100, donde alcanza el mayor solapamiento de todos los modelos, con 79%. Esto indica que, aunque su coincidencia en los primeros lugares es menor que la de ID_bin_lr, logra recuperar una proporción importante de los procesos considerados relevantes por el LLM cuando se amplía el rango de priorización.

Los índices probabilísticos ID_prob_lr e ID_prob_weighted presentan correlaciones positivas y niveles altos de solapamiento en los primeros cortes, especialmente en Top 10 y Top 20. Esto indica que también capturan parte importante de la señal del LLM, aunque su

ordenamiento general es menos cercano que el de los índices binarios principales. En contraste, los modelos aumentados, especialmente ID_bin_rf_aug, muestran una alineación más débil, con correlaciones bajas y un solapamiento muy reducido en los cortes superiores. Esto sugiere que estos modelos tienden a priorizar procesos distintos a los identificados por el LLM.

En conjunto, este segundo nivel de comparación indica que ID_bin_lr es el índice que más se aproxima al LLM en términos de ranking y priorización relativa de procesos, seguido por ID_bin_rf e ID_prob_lr.

El último nivel de comparación corresponde a la coincidencia en la priorización de procesos, evaluada mediante una clasificación binaria a nivel de proceso. Para ello, el *score* generado por el LLM fue transformado en una etiqueta binaria, utilizando un umbral de 0.5 para distinguir entre procesos acusatorios y no acusatorios. Posteriormente, se aplicó el mismo criterio a los índices evaluados, con el fin de comparar sus clasificaciones frente a la referencia generada por el LLM.

En este nivel se utilizaron métricas como *precision*, *recall*, *F1-score* y *accuracy*, con el objetivo de medir qué tan bien cada índice reproduce la clasificación binaria derivada del LLM. Este análisis permite evaluar no solo la cercanía distribucional o el ordenamiento relativo de los procesos, sino también la capacidad de cada índice para coincidir con el LLM en una decisión concreta: identificar qué procesos deberían ser considerados como acusatorios o de mayor prioridad para revisión.

A continuación, se presentan los resultados obtenidos:

Modelo	F1-Score	Precision	Recall	Accuracy
ID_bin_lr	1.000	1.000	1.000	1.000
ID_prob_weighted	0.9231	1.000	0.8571	0.9975
ID_prob_lr	0.8333	1.000	0.7143	0.9950
ID_bin_rf	0.5714	0.5714	0.5714	0.9850
ID_prob_rf	0.5455	0.7500	0.4286	0.9875
Kapak	0.3529	0.3000	0.4286	0.9725
ID_prob_rf_aug	0.0814	0.0424	1.000	0.6050
ID_bin_rf_aug	0.0761	0.0395	1.000	0.5750

Tabla 16. Desempeño de clasificación binaria de los índices por proceso frente al LLM

En la comparación binaria, ID_bin_lr alcanza coincidencia perfecta con la clasificación derivada del LLM bajo el umbral utilizado. Sin embargo, debido al posible desbalance de procesos positivos y negativos, estos valores deben interpretarse junto con las métricas anteriores y no de forma aislada.

En conjunto, los resultados muestran que el Prompt 15 logró una alineación sólida con las etiquetas humanas a nivel de pregunta y permitió construir una señal agregada de densidad acusatoria a nivel de proceso. Al comparar esta señal con los índices disponibles, se observan diferencias según la dimensión evaluada: algunos índices se aproximan mejor a la distribución del LLM, mientras que otros muestran mayor coincidencia en el ordenamiento o en la clasificación binaria de procesos. Estos hallazgos sugieren que la relación entre los índices clásicos y la señal semántica del LLM no es unidimensional, por lo que su interpretación requiere un análisis conjunto de similitud distribucional, ranking y desempeño binario. La discusión profundiza en estas diferencias y en sus implicaciones para la selección final del índice de riesgo.

Discusión

Interpretación general de los resultados.

Los resultados muestran que la construcción del índice no debe entenderse como la búsqueda de un único score “correcto”, sino como la identificación de una medida útil para propósitos analíticos distintos. La comparación cuantitativa y cualitativa sugiere que la propuesta final converge en tres índices particularmente defendibles: ID_bin_rf, ID_prob_lr e ID_prob_weighted. Cada uno resume la señal de riesgo desde un ángulo diferente y, por ello, su utilidad depende del tipo de decisión analítica que se quiera tomar.

En primer lugar, ID_bin_rf funciona bien como indicador de densidad binaria. Su principal fortaleza es la interpretabilidad: expresa la proporción de preguntas del proceso que fueron marcadas como acusatorias. Además, en la dimensión de parsimonia y calibración mostró el comportamiento más equilibrado frente a Kapak, evitando tanto la sobre-marcación masiva como la escasez extrema de positivos. Por eso, es el candidato más sólido cuando el objetivo es usar el índice como una regla práctica de tamizaje o una alerta inicial.

En segundo lugar, ID_prob_lr emerge como el mejor índice probabilístico individual. Su desempeño fue especialmente sólido en alineación con la línea base, discriminación y

robustez frente al tamaño del proceso. Esto sugiere que la regresión logística no solo produce probabilidades útiles a nivel de pregunta, sino que también genera un score agregado con buena capacidad para ordenar procesos según intensidad relativa de riesgo. Desde una perspectiva analítica, este índice es particularmente valioso cuando el objetivo no es clasificar dicotómicamente, sino priorizar y jerarquizar casos.

En tercer lugar, `ID_prob_weighted` destacó como el índice con mayor resolución distribucional y mayor consenso con la familia de modelos. Esto refuerza la validez de la propuesta de votación entre modelos: al combinar las señales de los tres clasificadores seleccionados, el índice ponderado no sustituye la interpretación de los índices individuales, pero sí ofrece una medida más estable cuando se busca capturar la parte compartida de la señal de riesgo. En otras palabras, parece ser la mejor opción cuando se privilegia robustez por consenso más que fidelidad a un modelo específico.

Discusión sobre la evolución de la propuesta del índice.

Un punto importante del trabajo es que la propuesta metodológica no fue lineal. En una primera etapa se consideraron alternativas más amplias de agregación, incluyendo formulaciones acumulativas y esquemas más complejos de combinación. Sin embargo, la exploración empírica mostró que varias de esas opciones introducían problemas de interpretación, especialmente en procesos con muchas preguntas, donde el índice podía crecer por mera acumulación de volumen textual y no por una mayor intensidad de acusatoriedad.

Se optó por conservar tres enfoques con significado sustantivo claro: la densidad binaria de preguntas acusatorias, el promedio probabilístico de los scores por pregunta y la votación entre modelos. Esta transición fortalece la tesis porque muestra que la selección metodológica no fue arbitraria, sino resultado de contrastar alternativas y descartar aquellas que no producían una señal útil o interpretable. A partir de esto, se tomó una decisión respecto al mejor método para construir el índice.

Selección del modelo con mayor alineación frente al LLM.

La comparación entre los índices y el esquema de LLM as a judge permite evaluar qué modelo reproduce de forma más consistente la señal semántica generada por el LLM a nivel de proceso. Sin embargo, esta selección no puede depender de una sola métrica, ya que cada

dimensión captura un aspecto distinto del comportamiento del índice. La similitud distribucional permite analizar si los puntajes tienen una forma global parecida; las métricas de ranking permiten evaluar si los procesos son ordenados de manera similar; y la comparación binaria permite observar si, bajo un umbral específico, los índices coinciden con el LLM en la identificación de procesos acusatorios o de mayor prioridad.

Desde esta perspectiva, el LLM no se interpreta como una verdad absoluta, sino como una referencia semántica complementaria. Por tanto, la selección del “mejor” modelo no busca determinar cuál índice prueba de manera definitiva la existencia de riesgo, sino cuál presenta mayor coherencia relativa con el criterio semántico aprendido por el LLM después del proceso de alineación del prompt.

Evaluación distribucional.

En la comparación de distribuciones, el índice con mejor comportamiento es ID_bin_rf. Este modelo presenta la menor distancia de Wasserstein y la menor divergencia Jensen-Shannon frente al LLM, lo que indica que su distribución global es la más cercana a la señal generada por el LLM en términos de distancia y forma probabilística. Además, su diferencia de desviación estándar es prácticamente nula, lo que sugiere que reproduce de manera muy similar el grado de dispersión de la densidad generada por el LLM.

No obstante, esta ventaja distribucional debe interpretarse con cautela. La distancia KS de ID_bin_rf es alta, lo que indica que existen diferencias relevantes entre las distribuciones acumuladas. Esto puede explicarse por la naturaleza del índice binario, cuyos valores tienden a concentrarse en fracciones discretas según el número de preguntas del proceso. En otras palabras, aunque ID_bin_rf se parece mucho al LLM en términos de distancia global, no necesariamente reproduce de forma idéntica la acumulación de valores a lo largo de todo el rango.

Por otro lado, ID_bin_rf_aug obtiene la menor distancia KS, pero presenta peor desempeño en Wasserstein y Jensen-Shannon. Además, sus gráficos muestran una tendencia más permisiva, con mayor desplazamiento hacia valores altos. Por esta razón, no debe considerarse el mejor índice distribucional en términos globales. Su menor KS parece reflejar

una coincidencia parcial en algún segmento de la distribución, pero no una similitud integral con la señal del LLM.

En síntesis, ID_bin_rf es el índice más defendible si la selección se basara exclusivamente en similitud distribucional. Sin embargo, dado que el objetivo práctico del índice es priorizar procesos, esta dimensión debe complementarse con el análisis de ranking.

Evaluación del ordenamiento de procesos.

El análisis de ranking es probablemente la dimensión más importante para la selección final, porque el objetivo operativo del índice es ordenar procesos según su nivel de riesgo textual. En esta dimensión, ID_bin_lr presenta el mejor desempeño de todos los modelos evaluados. Este índice alcanza las correlaciones más altas con el LLM en Spearman, Kendall y Pearson, lo que indica que reproduce de manera más consistente el ordenamiento relativo de los procesos generado por el LLM.

La correlación de Spearman muestra que ID_bin_lr es el índice que mejor conserva la relación monotonica con la densidad generada por el LLM. Esto significa que, cuando el LLM asigna mayor densidad acusatoria a un proceso, ID_bin_lr tiende también a ubicarlo en una posición más alta. A su vez, el valor elevado de Kendall indica una fuerte concordancia en el orden relativo de pares de procesos. Finalmente, el Pearson alto muestra que no solo existe similitud en el ranking, sino también una relación lineal fuerte entre los valores asignados por el índice y los valores generados por el LLM.

El Top-k overlap refuerza esta conclusión. ID_bin_lr alcanza el mayor solapamiento en los cortes más exigentes: 90% en Top 10 y 85% en Top 20. Esto es especialmente relevante porque, en un sistema de alerta temprana, los primeros puestos del ranking son los más importantes desde el punto de vista operativo. Si un organismo de control solo pudiera revisar un número reducido de procesos, el índice debería coincidir con el LLM precisamente en esa zona superior de riesgo. En este sentido, ID_bin_lr no solo se relaciona globalmente con el LLM, sino que también coincide con él en la priorización de los procesos más relevantes.

ID_bin_rf también muestra un desempeño sólido, especialmente en el Top 100, donde alcanza el mayor solapamiento. Esto sugiere que recupera una proporción amplia de procesos considerados importantes por el LLM cuando se amplía el rango de revisión. Sin embargo,

su menor coincidencia en Top 10 y Top 20 indica que no prioriza con la misma precisión los casos más extremos. Por ello, aunque ID_bin_rf es competitivo para una estrategia amplia de selección, ID_bin_lr resulta más fuerte cuando el objetivo es priorizar los procesos ubicados en los niveles superiores de riesgo.

Evaluación binaria frente al LLM.

La comparación binaria confirma nuevamente la fortaleza de ID_bin_lr. Bajo el umbral utilizado, este índice alcanza valores perfectos de F1-score, precision, recall y accuracy frente a la clasificación derivada del LLM. Esto significa que, al convertir los puntajes en una decisión binaria a nivel de proceso, ID_bin_lr reproduce completamente la clasificación del LLM dentro de la muestra evaluada.

Sin embargo, este resultado debe interpretarse con cuidado. La comparación binaria depende directamente del umbral seleccionado y puede ser sensible al desbalance entre procesos positivos y negativos. Por esta razón, no debe tomarse como evidencia aislada de superioridad absoluta. Aun así, el hecho de que ID_bin_lr también sea el mejor en ranking reduce el riesgo de que su buen desempeño binario sea únicamente un artefacto del umbral. En otras palabras, su fortaleza no aparece solo cuando se transforma en una etiqueta, sino también cuando se evalúa como sistema de priorización continua.

En esta misma comparación, ID_prob_weighted obtiene el segundo mejor desempeño, con F1-score de 0.9231, precision perfecta y recall de 0.8571. Esto lo convierte en la mejor alternativa probabilística frente al LLM. Además, en la comparación a nivel de pregunta, ID_prob_weighted también se comporta de manera consistente tanto frente al LLM como frente a la etiqueta humana. Por tanto, aunque no supera a ID_bin_lr en ranking ni en clasificación binaria a nivel de proceso, sí aparece como un índice probabilístico robusto y estable.

Desempeño de los modelos probabilísticos y binarios.

Los índices probabilísticos presentan un comportamiento más heterogéneo. ID_prob_lr muestra una relación lineal alta con el LLM y buen solapamiento en Top 10 y Top 20, pero su desempeño es inferior al de ID_bin_lr y ID_bin_rf en las métricas de ranking. Además, en la comparación binaria, aunque mantiene precision perfecta, su recall es menor que el de

ID_prob_weighted. Esto sugiere que ID_prob_lr puede ser útil como herramienta de ordenamiento continuo, pero no es el índice más alineado globalmente con el LLM dentro de esta evaluación.

ID_prob_weighted, en cambio, muestra una posición más equilibrada. Aunque no lidera las correlaciones de ranking, obtiene buenos resultados en la comparación binaria y en la evaluación a nivel de pregunta. Su ventaja conceptual es que combina señales de varios modelos, por lo que puede interpretarse como una medida de consenso. Esto lo hace menos dependiente de la idiosincrasia de un solo clasificador. Sin embargo, su distribución aparece desplazada hacia valores más altos que el LLM, lo que sugiere que tiende a asignar puntajes moderadamente superiores a una mayor proporción de procesos.

Los modelos ID_prob_rf_aug e ID_bin_rf_aug, muestran un patrón menos deseable. Aunque alcanzan recall alto en algunas comparaciones, su precisión es muy baja, lo que indica una tendencia a marcar demasiados casos como positivos. Esta conducta también se observa visualmente en sus distribuciones, que se desplazan hacia valores más altos respecto al LLM y Kapak. En términos operativos, esto puede generar un exceso de alertas y reducir la utilidad práctica del índice, especialmente en contextos donde los recursos de revisión son limitados. Por esta razón, los modelos aumentados no resultan adecuados como candidatos principales para la selección final.

Selección final.

Considerando de manera conjunta las tres dimensiones evaluadas, ID_bin_lr se selecciona como el índice con mayor alineación global frente al LLM. Aunque no es el mejor en la dimensión distribucional, domina claramente las métricas de ranking y la comparación binaria a nivel de proceso. Esta ventaja es especialmente importante porque el objetivo principal del índice no es solo reproducir una distribución general de puntajes, sino priorizar procesos de contratación para revisión. En ese sentido, las métricas de ordenamiento y solapamiento en los primeros cortes son más relevantes para el uso operativo del índice que la similitud distribucional por sí sola.

La selección de ID_bin_lr se justifica por tres razones principales. Primero, presenta las correlaciones más altas con el LLM, lo que indica que ordena los procesos de forma más

similar a la señal semántica generada por este. Segundo, obtiene el mayor solapamiento en los cortes superiores de priorización, especialmente en Top 10 y Top 20, que son los segmentos más relevantes para un sistema de alerta temprana. Tercero, reproduce perfectamente la clasificación binaria del LLM bajo el umbral utilizado, lo que refuerza su consistencia en una decisión concreta.

No obstante, esta selección debe presentarse con cautela. El resultado no significa que ID_bin_lr sea una verdad definitiva ni que los demás índices carezcan de utilidad. Más bien, indica que, dentro del ejercicio de validación semántica con LLM, ID_bin_lr es el índice que muestra mayor consistencia relativa con la señal agregada generada por el Prompt 15. En paralelo, ID_bin_rf se mantiene como el índice más cercano al LLM en términos distribucionales y puede ser útil para una lectura de densidad binaria más conservadora. Por su parte, ID_prob_weighted aparece como la alternativa probabilística más sólida, especialmente cuando se busca una medida de consenso entre modelos.

Por tanto, dado que el criterio de decisión es la alineación global con el LLM como referencia semántica complementaria, el índice seleccionado es ID_bin_lr. Sin embargo, se señala a ID_bin_rf como el índice con mayor similitud distribucional, e ID_prob_weighted como la mejor alternativa probabilística de consenso.

Es importante relacionar estos resultados con los perfiles originalmente definidos para la selección de modelos. El índice ID_bin_rf_aug y su versión probabilística ID_prob_rf_aug corresponden al Perfil 1: Alta Sensibilidad, basado en un modelo Random Forest entrenado con text-embedding-3-large y Consolidated Data Augmentation. Este perfil fue diseñado para minimizar falsos negativos, por lo que su tendencia a alcanzar altos valores de recall y a marcar una mayor cantidad de procesos como positivos es consistente con su objetivo inicial. Sin embargo, los resultados frente al LLM muestran que esta alta sensibilidad puede traducirse en un exceso de alertas y baja precisión.

Por otro lado, ID_bin_rf y ID_prob_rf corresponden al Perfil 2: Alta Precisión, también basado en Random Forest con text-embedding-3-large, pero entrenado sobre el dataset Balanced 4. Este perfil fue seleccionado por su capacidad para reducir falsos positivos y producir una clasificación más conservadora. En la comparación con el LLM, este

comportamiento se refleja especialmente en ID_bin_rf, que presenta la mayor similitud distribucional y mantiene una distribución más cercana a la señal del LLM.

Finalmente, ID_bin_lr e ID_prob_lr corresponden al Perfil 3: Equilibrado, basado en Logistic Regression con text-embedding-3-large y el dataset Balanced 4. Este perfil buscaba balancear sensibilidad y precisión, manteniendo una tasa moderada de falsos positivos. Los resultados frente al LLM muestran que esta lógica equilibrada se traduce en una fuerte capacidad de ordenamiento, especialmente en el caso de ID_bin_lr, que alcanza la mayor alineación en ranking y priorización de procesos. En este sentido, la comparación con el LLM refuerza la utilidad del perfil equilibrado como alternativa más consistente para la priorización relativa de procesos de riesgo.

Limitaciones del estudio.

El trabajo presenta varias limitaciones. En primer lugar, la línea base histórica de Kapak no constituye una verdad de referencia perfecta, ya que proviene de reglas y palabras clave, y puede contener tanto falsos positivos como falsos negativos. En segundo lugar, la ausencia de etiquetas supervisadas a nivel de proceso impide validar los índices finales contra un *ground truth* independiente. En tercer lugar, el uso de embeddings externos mantiene una dependencia tecnológica y de costos respecto al modelo de representación utilizado.

Una limitación adicional se relaciona con la propia construcción del índice a nivel de proceso. En una etapa inicial de la investigación se consideraron distintas familias de índices y funciones de agregación, incluyendo medidas de densidad, promedios probabilísticos, esquemas de consenso y formulaciones acumulativas como *Noisy-OR*. Sin embargo, la ausencia de una base de comparación independiente a nivel de proceso limitó la posibilidad de evaluar de manera objetiva todas estas alternativas. Por ejemplo, una función como *Noisy-OR* permite estimar la probabilidad de que al menos una pregunta dentro de un proceso sea acusatoria, pero no existía una etiqueta externa o criterio institucional suficientemente comparable para determinar si esa probabilidad acumulada representaba mejor el riesgo real del proceso. En consecuencia, se priorizaron índices más interpretables y comparables, especialmente aquellos basados en densidad o promedio de señales, ya que permitían una lectura más directa frente a Kapak, el LLM y las etiquetas disponibles.

Esta limitación implica que la selección final de los índices no debe interpretarse como la demostración absoluta de que las formas de agregación descartadas sean metodológicamente inválidas. Más bien, refleja una decisión práctica y conceptual ante la falta de un *ground truth* robusto a nivel de proceso. Algunas alternativas, como *Noisy-OR* u otros modelos acumulativos, podrían ser útiles en escenarios donde se disponga de una variable externa de validación, como resultados de auditoría, sanciones, observaciones institucionales o revisiones expertas completas por proceso. En el contexto de esta tesis, sin embargo, su interpretación era menos defendible porque tendían a responder preguntas distintas, por ejemplo, la probabilidad de al menos una señal acusatoria, y no necesariamente la densidad o intensidad promedio del riesgo textual.

A ello se suma una limitación conceptual: las preguntas acusatorias son una variable *proxy* de riesgo y no evidencia concluyente de corrupción. Por tanto, los índices construidos deben interpretarse como herramientas de priorización y no como pruebas o imputaciones. Aunque el análisis de 2021 permite estudiar distribuciones, niveles de consenso y relación con el monto contractual, todavía se requiere validación adicional con expertos y con otras modalidades de contratación.

Una limitación importante del estudio se relaciona con la naturaleza del etiquetado original del dataset. Las 5005 preguntas fueron clasificadas manualmente por estudiantes, por lo que las etiquetas utilizadas como referencia dependen de su criterio de interpretación. Aunque este procedimiento permite construir una base supervisada para entrenar y evaluar modelos, no constituye una verdad objetiva o absoluta. La identificación de una pregunta como “acusatoria” implica interpretar intención, tono, contexto y grado de imputación, elementos que pueden ser entendidos de manera distinta por diferentes personas.

Esta subjetividad puede introducir ruido en las etiquetas, especialmente en casos límite donde una pregunta puede leerse tanto como una crítica técnica o normativa como una acusación directa de irregularidad. En consecuencia, algunos desacuerdos entre los modelos, el LLM y las etiquetas originales no necesariamente reflejan errores claros, sino diferencias en la definición operativa de lo que se considera acusatorio. Esta limitación es relevante porque el desempeño cuantitativo de los modelos depende de la calidad y consistencia del conjunto etiquetado. Por tanto, los resultados deben interpretarse considerando que la base utilizada

representa una aproximación humana al fenómeno, susceptible a variabilidad, sesgos de interpretación y diferencias en el nivel de conocimiento sobre contratación pública.

El uso del LLM como juez también introduce limitaciones propias. Aunque el proceso de alineación del prompt permitió mejorar su consistencia frente a las etiquetas humanas, el LLM no debe entenderse como una fuente objetiva ni definitiva de verdad. Sus clasificaciones dependen directamente de la formulación del prompt, de los ejemplos incluidos, de las reglas de decisión especificadas y del comportamiento interno del modelo utilizado. Por ello, cambios en la redacción del prompt, en la versión del modelo, e incluso la configuración del nivel de “thinking” podrían producir variaciones en las clasificaciones obtenidas.

Además, el LLM fue utilizado como referencia semántica complementaria para comparar los índices, pero no reemplaza la validación experta. Su utilidad principal radica en ofrecer una lectura sistemática del contenido textual y facilitar la transición desde el nivel de pregunta hacia el nivel de proceso. Sin embargo, esta aproximación sigue estando limitada por la ambigüedad inherente del lenguaje, la sensibilidad del modelo a casos límite y la posibilidad de reproducir sesgos presentes en los datos o en las instrucciones utilizadas para alinearlos.

También debe considerarse que la comparación entre los índices y el LLM se realizó sobre una muestra limitada de procesos de 2021. Aunque esta muestra permitió construir una señal agregada de densidad acusatoria a nivel de proceso, los resultados no deben interpretarse como evidencia concluyente de superioridad de un índice en todos los contextos. La cercanía entre un índice y el LLM indica consistencia relativa con una referencia semántica específica, pero no prueba que dicho índice detecte corrupción real ni que generalice necesariamente a otros años, modalidades de contratación o conjuntos documentales.

Por esta razón, el índice propuesto no debe entenderse como una medida definitiva de corrupción, sino como una herramienta de priorización basada en señales textuales que requieren interpretación contextual y validación complementaria.

Conclusiones

El principal aporte de esta tesis consiste en haber transformado la detección automática de preguntas acusatorias en un conjunto de índices de riesgo a nivel de proceso, con un

significado más interpretable y útil para el análisis de los procesos de contratación pública. A diferencia de una clasificación aislada a nivel de pregunta, los índices propuestos permiten agregar señales textuales dentro de cada proceso y convertirlas en medidas comparables de riesgo. Más que proponer una única medida definitiva, el trabajo demuestra que el fenómeno puede entenderse mejor mediante enfoques complementarios: un índice de densidad binaria de preguntas acusatorias, índices probabilísticos promedio que capturan la intensidad de la señal, y un índice de consenso entre modelos que resume información proveniente de clasificadores distintos.

En términos metodológicos, la investigación también evidencia una evolución importante respecto de la propuesta inicial. En una primera etapa se consideraron alternativas de agregación más amplias y complejas, incluyendo formulaciones acumulativas y probabilísticas. Sin embargo, no todas estas alternativas eran igualmente interpretables ni comparables. Por esta razón, el sistema final priorizó medidas más simples, estables y comunicables, capaces de representar de manera clara la prevalencia, la intensidad y el consenso de las señales acusatorias. Esto fortaleció la coherencia del marco propuesto y permitió construir índices más adecuados para contextos institucionales, donde la trazabilidad y la interpretación son tan importantes como el desempeño estadístico.

Los resultados muestran que los índices derivados de los siete modelos iniciales cumplen funciones diferenciadas y capturan aspectos distintos de la señal de riesgo. En lugar de reducir el sistema final a un único índice, se mantuvo el conjunto completo de modelos para conservar una lectura más amplia del fenómeno y comparar distintos comportamientos de agregación. Los índices binarios, como ID_bin_rf, ID_bin_lr e ID_bin_rf_aug, permiten una interpretación directa basada en la proporción de preguntas clasificadas como acusatorias dentro de cada proceso. Por su parte, los índices probabilísticos, como ID_prob_lr, ID_prob_rf, ID_prob_rf_aug e ID_prob_weighted, preservan información continua sobre la intensidad de la señal, lo que puede ser útil para el ordenamiento y la discriminación de procesos. En particular, ID_prob_weighted funciona como una medida de consenso entre modelos, reduciendo la dependencia de un único clasificador y ofreciendo una lectura más robusta cuando varias fuentes coinciden en identificar riesgo. En conjunto, los siete índices no deben entenderse como sustitutos directos, sino como herramientas complementarias que

permiten analizar el riesgo textual desde perspectivas distintas dentro de un sistema de priorización.

La incorporación del esquema de “LLM as a judge” constituyó un aporte adicional al proceso de evaluación. Su función no fue reemplazar el etiquetado humano ni establecer una verdad definitiva, sino ofrecer una referencia semántica complementaria para contrastar la coherencia de los índices. El proceso de alineación del prompt permitió refinar la definición operativa de “pregunta acusatoria”, distinguiéndola de preguntas meramente críticas, técnicas o normativas. Esto mostró que una parte central del problema no consiste únicamente en clasificar correctamente, sino en delimitar con precisión qué debe entenderse como acusación en el contexto de contratación pública.

Los resultados del LLM también evidenciaron que la cercanía entre los índices y una referencia semántica no es unidimensional. Algunos índices se aproximan mejor a la distribución generada por el LLM, mientras que otros muestran mayor coincidencia en el ordenamiento o en la clasificación binaria de procesos. En particular, los análisis de comparación sugieren que ID_bin_lr presenta una fuerte alineación con el LLM en términos de ranking y priorización relativa, mientras que ID_bin_rf destaca por su similitud distribucional e ID_prob_weighted aparece como una alternativa probabilística consistente. Sin embargo, estos resultados deben interpretarse con cautela, ya que el LLM constituye una referencia complementaria y no un ground truth independiente. Por tanto, el ejercicio con LLM enriquece la discusión metodológica, pero no debe ser utilizado como único criterio de selección.

En conjunto, esta tesis demuestra que es posible construir medidas textuales de riesgo con valor analítico a partir de preguntas formuladas en procesos de contratación pública. Estas medidas no constituyen evidencia concluyente de corrupción, pero sí pueden funcionar como herramientas de priorización para orientar revisiones, auditorías o análisis institucionales más detallados. Al mismo tiempo, los resultados subrayan que la utilidad de estos índices depende tanto de su desempeño estadístico como de la claridad conceptual con la que se define el fenómeno que buscan capturar. Desde esta perspectiva, el trabajo no solo propone índices concretos, sino también un marco metodológico para abordar con mayor rigor la medición de señales de riesgo basadas en lenguaje.

Recomendaciones y trabajos futuros

A partir de las limitaciones identificadas y de los resultados obtenidos, se plantean varias líneas de mejora y posibles trabajos futuros. En primer lugar, sería recomendable diseñar desde el inicio un marco de evaluación que permita comparar los índices en todos los niveles de análisis de manera más homogénea. En esta tesis, la comparación entre índices y el LLM estuvo parcialmente condicionada por la propia fórmula de cálculo de cada índice. Por ejemplo, los índices binarios y los índices probabilísticos viven en la misma escala $[0,1]$, pero no representan exactamente lo mismo: los primeros expresan densidad de decisiones positivas, mientras que los segundos representan promedios de probabilidades. Esta diferencia puede sesgar la interpretación de qué tan “cercano” está un índice respecto al LLM. Por ello, un trabajo futuro podría desarrollar una metodología de normalización, calibración o equivalencia entre tipos de índice, de modo que las comparaciones entre densidades binarias, probabilidades promedio y medidas de consenso sean más justas y metodológicamente consistentes.

Una segunda recomendación es fortalecer la validación humana del sistema. Aunque el uso del LLM permitió construir una referencia semántica complementaria, el siguiente paso debería consistir en regresar al criterio experto humano, especialmente a nivel de proceso. Para ello, sería útil construir un nuevo conjunto de evaluación en el que expertos en contratación pública revisen procesos completos y no únicamente preguntas aisladas. Esta revisión debería incluir todas las preguntas de cada proceso, las respuestas de la entidad, los pliegos, los tiempos de respuesta, los documentos asociados, el comportamiento de los oferentes y otros elementos relevantes del contexto. De esta manera, se podría asignar un veredicto o score de riesgo más informado a nivel de proceso, que sirva como base de comparación más sólida para evaluar los índices.

También sería importante ampliar el proceso de etiquetado. En lugar de depender únicamente de etiquetas a nivel de pregunta, futuros estudios podrían construir etiquetas jerárquicas o multinivel: primero a nivel de pregunta, luego a nivel de conjunto de preguntas dentro del proceso y finalmente a nivel del proceso completo. Esto permitiría evaluar si la acumulación de señales textuales realmente se traduce en un mayor riesgo percibido del proceso.

Otra línea futura consiste en mejorar la forma en que se interpretan y utilizan los modelos probabilísticos. Los resultados sugieren que los modelos basados en probabilidad pueden ser útiles para capturar intensidad y ordenar procesos, pero su comparación con índices binarios no siempre es directa. Por ello, una posible extensión sería desarrollar una metodología específicamente probabilística para agregar señales a nivel de proceso.

Asimismo, futuros trabajos podrían traducir los puntajes continuos de riesgo en categorías operativas más interpretables, como riesgo bajo, medio y alto. Esta clasificación facilitaría el uso institucional del índice, ya que los organismos de control no siempre requieren un valor numérico exacto, sino una priorización clara para decidir qué procesos revisar primero. Para ello, sería necesario definir umbrales de riesgo de manera cuidadosa, idealmente combinando evidencia estadística, revisión experta y criterios prácticos de capacidad institucional.

También se recomienda evaluar la estabilidad temporal y externa del índice. En esta tesis, el análisis se enfocó principalmente en procesos de Subasta Inversa Electrónica del año 2021. Un trabajo futuro podría aplicar la misma metodología a otros años y modalidades de contratación para determinar si los índices conservan su comportamiento en contextos distintos. Esto permitiría identificar si el índice captura una señal generalizable de riesgo textual o si su desempeño depende de características particulares del año, del tipo de procedimiento o de los datos disponibles.

Finalmente, una línea prometedora sería integrar las señales textuales con otros indicadores estructurados de riesgo. Las preguntas acusatorias aportan una dimensión semántica valiosa, pero no deberían analizarse de manera aislada. En trabajos futuros, el índice textual podría combinarse con variables como monto contractual, número de oferentes, duración del proceso, modificaciones al pliego, historial de la entidad, concentración de proveedores o alertas tradicionales de Kapak. Esta integración permitiría construir un sistema de priorización más completo, donde el lenguaje de los oferentes funcione como una capa adicional dentro de un marco más amplio de monitoreo de riesgo en contratación pública.

Referencias y bibliografía

- Alzahrani, S., Al-Bander, B., & Al-Nuaimy, W. (2021). A comprehensive evaluation and benchmarking of convolutional neural networks for melanoma diagnosis. *Cancers*, 13(17), 4494. <https://doi.org/10.3390/cancers13174494>
- Bhattacharjee, K., Pant, M., & Srivastava, S. (2021). Evolutionary multiple instance boosting framework for weakly supervised learning. *Complex & Intelligent Systems*. <https://doi.org/10.1007/s40747-021-00469-9>
- Bui, L. (2026). Legal and regulatory challenges in addressing high-tech crimes in the banking sector: Developing a cybersecurity risk assessment framework for Vietnam. *Journal of Banking Regulation*, 27(1). <https://doi.org/10.1057/s41261-025-00302-0>
- Cho, M., Ban, H.-J., Nam, H. R., Chu, C. H., Jeon, J. P., & Kim, S. C. (2025). A machine learning framework for classifying dementia risk in mild cognitive impairment. *Alzheimer's Research & Therapy*, 17(1). <https://doi.org/10.1186/s13195-025-01894-5>
- Decarolis, F., & Giorgiantonio, C. (2022). Corruption red flags in public procurement: New evidence from Italian calls for tenders. *EPJ Data Science*, 11(1), 16. <https://doi.org/10.1140/epjds/s13688-022-00325-x>
- Fazekas, M., & Kocsis, G. (2020). Uncovering high-level corruption: Cross-national objective corruption risk indicators using public procurement data. *British Journal of Political Science*, 50(1), 155–164. <https://doi.org/10.1017/S0007123417000461>
- Fazekas, M., Tóth, I. J., & King, L. P. (2016). An objective corruption risk index using public procurement data. *European Journal of Criminal Policy and Research*, 22(3), 369–397. <https://doi.org/10.1007/s10610-016-9308-z>
- Ferwerda, J., Deleanu, I., & Unger, B. (2017). Corruption in public procurement: Finding the right indicators. *European Journal of Criminal Policy and Research*, 23(2), 245–267. <https://doi.org/10.1007/s10610-016-9312-3>

- Fuduli, A., Gaudioso, M., Khalaf, W., & Vocaturo, E. (2022). A heuristic approach for multiple instance learning by linear separation. *Soft Computing*, 26(7), 3361–3368. <https://doi.org/10.1007/s00500-021-06713-1>
- Gallego, J., Rivero, G., & Martínez, J. D. (2021). Preventing rather than punishing: An early warning model of malfeasance in public procurement. *International Journal of Forecasting*, 37(1), 360–377.
- García Rodríguez, M. J., Rodríguez-Montequín, V., Ballesteros-Pérez, P., Love, P. E. D., & Signor, R. (2022). Collusion detection in public procurement auctions with machine learning algorithms. *Automation in Construction*, 133, 104047. <https://doi.org/10.1016/j.autcon.2021.104047>
- Gnaldi, M., & Del Sarto, S. (2024). Measuring corruption risk in public procurement over emergency periods. *Social Indicators Research*, 172(2), 859–877. <https://doi.org/10.1007/s11205-024-03331-w>
- Gonzalez, L. F. (2026). Predicting gender from online dating self-introductions using machine learning, deep learning, and DistilBERT. *Journal of Applied Data Sciences*, 7(1), 489–505. <https://doi.org/10.47738/jads.v7i1.979>
- Goryunova, N., Baklanov, A., & Ianovski, E. (2021). Detecting corruption in single-bidder auctions via positive-unlabelled learning. *arXiv*. <https://arxiv.org/abs/2102.05523>
- Govindarajan, V., Ahmed, F., Kamaluddin, K., Mushtaq, Z., Alshammari, K., & Khan, F. (2026). SecureRiskNet: An advanced AI-driven framework for intelligent security risk detection in heterogeneous cloud-fog computing networks. *International Journal of Computational Intelligence Systems*, 19(1). <https://doi.org/10.1007/s44196-025-01117-7>
- Gu, J., Jiang, X., Shi, Z., Tan, H., Zhai, X., Xu, C., Li, W., Shen, Y., Ma, S., Liu, H., Wang, S., Zhang, K., Lin, Z., Zhang, B., Ni, L., Gao, W., Wang, Y., & Guo, J. (2026). A survey on LLM-as-a-judge. *The Innovation*, 101253. <https://doi.org/10.1016/j.xinn.2025.101253>

- Harman, J. L., & Scheuerman, J. (s.f.). Multi-criteria comparison as a method of advancing knowledge-guided machine learning.
- Li, J. (2024). Area under the ROC curve has the most consistent evaluation for binary classification. *PLOS ONE*, 19(12), e0316019. <https://doi.org/10.1371/journal.pone.0316019>
- Li, L. (2026). Modeling of an English speaking scoring system integrating natural language processing techniques. *Discover Artificial Intelligence*, 6(1). <https://doi.org/10.1007/s44163-025-00763-2>
- Lima, M. C., de Carvalho, L. R., de Souza Mendes, F. L., da Costa Silva, R., Araujo, A., & Vidal, F. B. (2020). Inferring fraudulent collusion risk on Brazilian public works contracts using Bi-LSTM. *Findings of EMNLP 2020*, 1580–1588.
- Lima, W., Lira, R., Paiva, A., Silva, J., & Silva, V. (2023). Methodology for automatic extraction of red flags in public procurement. *Proceedings of the IEEE ICTAI*. <https://doi.org/10.1109/ICTAI56018.2022.00178>
- Lisciandra, M., Milani, R., & Millemaci, E. (2022). A corruption risk indicator for public procurement. *European Journal of Political Economy*, 73, 102141. <https://doi.org/10.1016/j.ejpoleco.2021.102141>
- Lorenz, J., Brauer, C., & Lorenz, D. (2016). Rank-optimal weighting. *Social Indicators Research*, 134(1), 75–92. <https://doi.org/10.1007/s11205-016-1416-0>
- Luna-Ortega, J. C., Cobos-Lozada, C. A., & Mendoza-Becerra, M. E. (2023). Modelo para definir índices de corrupción en contratación pública en Colombia. *Revista Científica*, 46(1), 77–92. <https://doi.org/10.14483/23448350.19640>
- Modrusan, N., Rabuzin, K., & Mrsić, L. (2020). Improving public sector efficiency using text mining. *CEUR Workshop Proceedings*.
- Nai, R., Sulis, E., & Meo, R. (2022). Public procurement fraud detection and AI techniques: A literature review. *CEUR Workshop Proceedings*.

- Norberg, A., et al. (2019). Evaluation of predictive performance of species distribution models. *Ecological Monographs*, 89(3), e01370. <https://doi.org/10.1002/ecm.1370>
- Polo, T. C., & Miot, H. A. (2020). Aplicações da curva ROC. *Jornal Vascular Brasileiro*, 19. <https://doi.org/10.1590/1677-5449.200186>
- Riaz, G., et al. (2025). A robust anomaly detector for imbalanced data. *Journal of Computational Design and Engineering*, 12(9), 46–60. <https://doi.org/10.1093/jcde/qwaf085>
- Roh, F., & Grijalva, F. (2024). Detection of accusatory comments in Ecuadorian public procurement processes using NLP [Manuscrito no publicado]. Universidad San Francisco de Quito.
- Salazar, A., Perez, J. F., & Gallego, J. (2024). VigIA: Prioritizing public procurement oversight with machine learning models. *Data & Policy*, 6, e75. <https://doi.org/10.1017/dap.2024.83>
- Steyerberg, E. W., et al. (2010). Assessing the performance of prediction models. *Epidemiology*, 21(1), 128–138. <https://doi.org/10.1097/EDE.0b013e3181c30fb2>
- Tian, H., et al. (2026). Machine learning-based prediction of recovery in stroke patients. *BMC Medical Informatics and Decision Making*, 26(1).
- Wang, D., et al. (2015). Optimizing AUC using semi-supervised learning. *Pattern Recognition*, 48(1), 276–287. <https://doi.org/10.1016/j.patcog.2014.07.025>
- Werner, E. (2011). Unbiased risk estimation and scoring rules. *Comptes Rendus Mathématique*, 349(11–12), 699–702. <https://doi.org/10.1016/j.crma.2011.04.015>

