



COLEGIO DE CIENCIAS E INGENIERÍAS

INGENIERÍA EN CIENCIAS DE LA COMPUTACIÓN

Planificación para el Desarrollo del Proyecto Integrador

Tutor: Daniel Riofrío

Autor: Daniela Salazar

Quito – Ecuador
2026



1. Título del Proyecto:

Diseño e implementación de un índice de riesgo de corrupción basado en preguntas acusatorias del portal de contratación pública ecuatoriano para procesos de Subasta Inversa Electrónica

2. Relevancia y Justificación:

La corrupción es uno de los problemas más graves dentro del contexto de la contratación pública en América Latina, incluyendo particularmente al Ecuador, a causa de su impacto negativo en varios ámbitos como el gasto público, la credibilidad de las instituciones públicas, y la calidad de los servicios ofrecidos al país. Frente a este escenario, se han adoptado múltiples estrategias enfocadas en la transparencia y la gestión digital de los procesos de contratación. No obstante, el acceso a la información no es suficiente para garantizar una mejor supervisión y control en dicho ámbito. Como la información no tiene un orden claro, es muy pesado y difícil de estudiar.

En este contexto, plataformas como el Sistema Oficial de Contratación Pública del Ecuador (SOCE) generan un volumen masivo de registros escritos que documentan la relación e interacción directa entre los proveedores invitados y las entidades contratantes. En estas interacciones, las preguntas y respuestas emitidas por ambas partes durante los procesos de contratación proporcionan una fuente de información valiosa. Al participar en estos procesos, los oferentes tienen sus propias motivaciones e interés directo en exponer posibles irregularidades, tales como inconsistencias en las condiciones del contrato. Bajo esta perspectiva, dichas preguntas y comentarios manifiestan las opiniones de los proveedores, que funcionan como una herramienta con potencial informativo, pero que hasta ahora apenas ha sido aprovechado en análisis o estudios respecto al tema.

Pese a su relevancia, la información de tipo texto no suele sistematizarse o cuantificarse de manera objetiva, lo que restringe su uso para la detección e identificación de señales de alerta de riesgo durante las etapas de un proceso de contratación. Bajo este escenario, el presente trabajo se integra en el proyecto Kapak, una plataforma de indicadores diseñada para la identificación de riesgos de corrupción en compra pública. La herramienta utiliza como fuente primaria los datos públicos generados por el Sistema Oficial de Contratación Pública del Ecuador (SOCE), bajo la gestión del Servicio Nacional de Contratación Pública (SERCOP).

A partir de este marco, el proyecto no se limita a la clasificación binaria de texto, sino que se enfoca en profundizar el diseño y la validación de uno de los componentes del proyecto Kapak, específicamente la transformación de las salidas del modelo en un índice reproducible y cuantificable. Este enfoque busca superar el uso de etiquetas 0/1, proponiendo una métrica que capture la intensidad del riesgo. Esto permitirá jerarquizar los procesos según qué tan críticos son, poniendo mayor énfasis en aquellos casos con mayor probabilidad de irregularidad. La construcción de un pipeline reproducible que se base en modelos previamente desarrollados en el proyecto Kapak, permite aplicar el indicador e índice sobre datos históricos de contratación pública en el periodo 2008–2024. Puntualmente, el estudio se centra en la identificación de preguntas acusatorias, entendiéndolas como una variable aproximada (proxy) de posibles conflictos o irregularidades percibidos. Este análisis es significativo debido a que tales cuestionamientos son una evidencia directa de las dudas o denuncias que un proveedor puede manifestar respecto a la integridad de la contratación.

Por consiguiente, el valor de este proyecto radica en la integración de técnicas de machine learning y ciencia de datos, con un énfasis en la investigación y el análisis comparativo de modelos previamente



desarrollados. En lugar de partir desde cero, el estudio se apoya en los modelos ya construidos en el proyecto Kapak, profundizando en la definición y justificación de criterios de selección que permitan identificar los dos modelos con mejor desempeño según métricas relevantes.

A partir de esta base metodológica, se aplica y valida el indicador propuesto sobre procesos de contratación de tipo Subasta Inversa Electrónica (SIE), siendo complementado con un análisis cualitativo de casos seleccionados. La elección de procesos SIE se fundamenta en que se integra directamente con los módulos de análisis del proyecto Kapak. Finalmente, la investigación aporta no solamente dentro del ámbito académico, al formalizar un proceso reproducible de selección y uso de modelos, sino que a su vez promueve políticas de control que involucran la ciencia de datos para mejorar la transparencia.

3. Objetivos

a. Generales

Diseñar e implementar un índice de riesgo asociado a preguntas acusatorias en procesos de contratación pública del Ecuador, mediante la aplicación de técnicas de machine learning y procesamiento de lenguaje natural (NLP), con el fin de caracterizar, jerarquizar y analizar los procesos de Subasta Inversa Electrónica (SIE) utilizando datos históricos del periodo 2008–2024.

b. Específicos

1. Realizar un análisis comparativo de los modelos de clasificación de preguntas acusatorias desarrollados previamente en el proyecto Kapak, utilizando métricas de desempeño robustas y un análisis exhaustivo del equilibrio (trade-off) entre falsos positivos y falsos negativos, con el fin de justificar la selección de los dos modelos más adecuados para la construcción del indicador e índice de riesgo.
2. Asegurar que los dos modelos seleccionados sean reproducibles mediante la reconstrucción y validación de un pipeline, garantizando la consistencia de los resultados y que puedan aplicarse sobre los datos provenientes del Sistema Oficial de Contratación Pública del Ecuador.
3. Definir y formalizar un indicador de detección de comportamiento irregular, basado en las salidas del modelo de clasificación, estableciendo su forma de cálculo, escala e interpretación a nivel de pregunta y proceso de contratación.
4. Desarrollar un índice de riesgo con base en los resultados generados por el modelo de clasificación, que permita capturar la intensidad del riesgo y jerarquizar los procesos de contratación de acuerdo con qué tan críticos son.
5. Implementar computacionalmente el indicador y el índice de riesgo propuestos, integrando los modelos de clasificación seleccionados con los datos estructurados de Kapak, y construyendo un pipeline que garantice el cálculo consistente de las métricas de riesgo a nivel de proceso.
6. Analizar de manera descriptiva las señales de riesgo detectadas por el índice en los procesos de Subasta Inversa Electrónica (SIE), cubriendo el periodo 2008-2024.
7. Comparar los resultados obtenidos mediante el indicador y el índice de riesgo con la información previamente disponible en la base de datos, para identificar los aportes adicionales.
8. Realizar una validación cualitativa del indicador y del índice de riesgo, mediante un análisis profundo de un subconjunto de procesos y preguntas, con el objetivo de evaluar la coherencia entre los valores obtenidos y el texto original.



4. Estado del Arte

Para el Estado del Arte, se identificaron cuatro líneas de investigación principales

Medición del riesgo de corrupción en contratación pública mediante proxys

La literatura reciente sobre la medición del riesgo de corrupción en la contratación pública ha evolucionado desde el uso enfoques basados en percepciones y el uso de proxys contruidos a partir de datos administrativos. Este cambio fue una respuesta a la dificultad de observar directamente la corrupción y a la necesidad de contar con métricas reproducibles y comparables. En este contexto, el trabajo de Fazekas et al. (2016) fue muy importante porque propuso una metodología sistemática para la construcción de un Índice de Riesgo de Corrupción (CRI), basado en la combinación y validación estadística de múltiples “banderas rojas” (red flags), tales como la oferta única (single bidding) o el uso de procedimientos no abiertos. Posteriormente, Fazekas y Kocsis (2020) consolidaron este enfoque al demostrar que la restricción de la competencia deja rastros observables en los datos de contratación, identificando al single bidding como uno de los indicadores de resultado más robustos para capturar riesgos de corrupción en instituciones. Este marco teórico distingue entre manipulaciones del proceso (inputs) y resultados de mercado corruptos (outputs), lo que fue fundamental para el análisis empírico del riesgo de corrupción a nivel de proceso.

No obstante, hubo evaluaciones críticas en cuanto a la validez y competencia de los proxys tradicionales. Ferwerda et al. (2017), mediante el uso de muestras balanceadas de casos corruptos confirmados y grupos de control, evidencian que solo un subconjunto de las “red flags” comúnmente utilizadas tiene poder predictivo realmente significativo, haciendo énfasis en la parte metodológica de la selección de indicadores. Decarolis y Giorgiantonio (2022) muestran que los actores corruptos pueden adaptarse para evitar señales evidentes, lo que incluso genera correlaciones negativas entre ciertos indicadores tradicionales y la corrupción real. Ellos les dan valor a indicadores más sutiles, frecuentemente introducidos en los documentos del proceso, cuya identificación manual resulta costosa a gran escala. Frente a este desafío, estudios recientes como el de Lima et al. (2023) incorporan técnicas de procesamiento de lenguaje natural para extraer automáticamente señales textuales profundas desde los documentos de contratación.

Uso de datos no estructurados y procesamiento de lenguaje natural en el sector público

La literatura reciente sobre la detección de riesgos en la contratación pública muestra una transición desde el análisis exclusivo de datos estructurados hacia el uso de fuentes no estructuradas, particularmente texto, mediante técnicas de Procesamiento de Lenguaje Natural (NLP). Este cambio fue un resultado de la creciente disponibilidad de documentos administrativos, contratos, pliegos y registros de interacción que contienen información semántica relevante pero difícil de capturar con métodos tradicionales. En un inicio, los estudios se apoyaron en enfoques basados en reglas y extracción de palabras clave, combinados con modelos clásicos de machine learning como Support Vector Machines (SVM), tal como muestran Modrusan et al. (2020). Sin embargo, otras revisiones sistemáticas, como la de Gomes y Colaço (2022), prueban que cada vez más se busca adoptar arquitecturas de deep learning, incluyendo redes neuronales convolucionales y recurrentes (CNN y RNN), para la clasificación de descripciones textuales en registros administrativos.

Más recientemente se han incorporado modelos basados en Transformers, que han demostrado un mejor desempeño en tareas de análisis de textos en contextos institucionales. Lima et al. (2023) muestran que modelos como BERT permiten extraer “banderas rojas” directamente desde contratos, lo que ha superado a los métodos basados en reglas porque logra capturar relaciones semánticas profundas. Nai et al. (2023) emplean sentence embeddings (SBERT) para vincular semánticamente descripciones de licitaciones con

sentencias judiciales. Asimismo, Torres-Berru et al. (2023) introducen un enfoque basado en conducta al aplicar word embeddings y análisis de sentimientos a registros de preguntas y respuestas (Q&A), lo que revela sesgos o favoritismos que no son evidentes en los documentos formales del proceso. Para manejar la gran variedad de términos y palabras que se usan, Pastor-Sanz et al. (2024) usaron un sistema llamado Latent Dirichlet Allocation (LDA) que agrupa automáticamente los textos de los contratos. Esto permite convertir párrafos desordenados en 'perfiles de riesgo' que una computadora puede usar para predecir problemas. En resumen, estos estudios demuestran que el uso de NLP sobre datos no estructurados amplía la capacidad analítica de los sistemas, ya que permite incorporar señales semánticas en la evaluación del riesgo en la contratación pública.

Selección y evaluación de modelos de machine learning para detección de riesgos

El uso de machine learning ha creado una nueva forma de medir el riesgo de corrupción que va mucho más allá de los métodos antiguos. Ya no se trata solo de sumar errores en una lista o de usar fórmulas matemáticas tradicionales. Ahora, estas herramientas de inteligencia artificial pueden analizar toda la información en conjunto para detectar sospechas que antes eran imposibles de ver. A diferencia de los índices contruidos mediante combinaciones lineales de banderas rojas, los modelos de aprendizaje automático permiten estimar directamente un score de riesgo, que se entiende como la probabilidad de que un proceso contractual esté asociado a prácticas irregulares, a partir del aprendizaje de patrones complejos en datos históricos masivos (Gallego et al., 2021). Este enfoque ha demostrado ser especialmente útil en contextos donde las interacciones entre variables son no lineales y difíciles de modelar explícitamente.

Sin embargo, la selección y evaluación de estos modelos no debe centrarse únicamente en maximizar métricas de desempeño, como el accuracy, sino en considerar las implicaciones para las instituciones. García Rodríguez et al. (2022), tras comparar once algoritmos en múltiples países, evidenciaron que los métodos de ensamble, como Random Forest y Extra Trees, dan un mejor desempeño en métricas frente a modelos lineales y redes neuronales básicas. No obstante, la capacidad del modelo depende del contexto específico de aplicación. Gallego et al. (2021) marcan que, dado el fuerte desbalance de clases característico de los casos de fraude, métricas tradicionales como la curva ROC pueden resultar insuficientes, para lo que proponen evaluaciones basadas en la simulación de los costos asociados a falsos positivos y falsos negativos. Lima et al. (2020) argumentan que, en escenarios con recursos limitados, debe priorizarse la precisión para evitar generar demasiadas alertas sin fundamentos. Finalmente, Salazar et al. (2024) destacan que la interpretabilidad es un factor clave para adoptar este tipo de sistemas, favoreciendo modelos que, además de que tienen un buen desempeño para predecir, permiten explicar las alertas generadas mediante medidas como la importancia de variables, facilitando su uso por organismos de control.

Construcción de indicadores e índices de riesgo en contextos institucionales

Antes, para detectar riesgos de corrupción en contratación pública, se usaban fórmulas muy simples. Ahora, se emplean métodos mucho más avanzados que permiten entender mejor la complejidad de este problema. Una de las familias metodológicas más desarrolladas se basa en agregar banderas rojas (red flags), entendidas como características anómalas observables en los procesos de contratación. Fazekas et al. (2016) establecen un estándar al proponer el Índice de Riesgo de Corrupción (CRI), en el cual la importancia (el peso) de cada indicador se basa en su capacidad real para predecir situaciones donde no hay competencia, como cuando solo se presenta una empresa. En contraste, Fazekas y Kocsis (2020) buscaron hacer un promedio aritmético con pesos iguales.



Al mismo tiempo, han aparecido nuevas formas de medir la corrupción que no solo se limitan a sumar errores aislados, sino que miran el problema de raíz. Por ejemplo, Lisciandra et al. (2022) proponen un modelo que ayuda a distinguir entre la ineficiencia técnica (errores por falta de capacidad o recursos) y la sospecha de corrupción; para ellos, el riesgo real es aquello que no tiene una explicación lógica después de analizar qué tan bien se manejó un contrato. Por otro lado, Gallego et al. (2021) utilizan la inteligencia artificial para que las computadoras aprendan de millones de datos históricos y así encuentren patrones sospechosos que son demasiado complejos para el ojo humano.

Sin embargo, expertos como Gnaldi y Del Sarto (2024) advierten que el riesgo de corrupción tiene muchas caras y no debería resumirse en un solo número, ya que eso simplifica demasiado el problema. En esa misma línea, Blancas y Contreras (2024) sugieren usar modelos híbridos que eviten que un "buen comportamiento" en un área del contrato termine ocultando una alerta grave en otra. En definitiva, la tendencia actual busca crear herramientas que sean matemáticamente sólidas, pero, sobre todo, útiles para que los auditores decidan rápidamente qué procesos investigar.

5. Metodología de Trabajo

El proyecto se desarrollará utilizando una metodología híbrida tipo secuencial–iterativa, correspondiente al Iterative Waterfall Model, el cual permite estructurar el trabajo en fases claramente definidas, incorporando iteraciones controladas propias de proyectos de investigación aplicada en ciencia de datos y machine learning.

La adopción de esta metodología permite que el proceso sea ordenado, reproducible y verificable, garantizando que las decisiones tomadas en las etapas iniciales (fundamentación teórica, selección de modelos y diseño del sistema de métricas) guíen coherentemente las fases de implementación y análisis. Asimismo, este enfoque facilita la validación progresiva del indicador y del índice de riesgo propuestos.

Fase 1: revisión y fundamentos teóricos

En esta primera etapa se va a realizar una revisión del estado del arte con el fin de adquirir y fortalecer conocimientos teóricos y metodológicos relacionados con:

- análisis de corrupción y riesgos en contratación pública,
- uso de datos no estructurados en estudios institucionales,
- la aplicación de técnicas de procesamiento de lenguaje natural y machine learning para la clasificación de texto

Para esta revisión se consultarán bases de datos especializadas como Scopus y Web of Science, lo que servirá para situar el estudio dentro de la literatura existente y dar una base sólida a las decisiones tomadas en la metodología.

Adicionalmente, esta fase incluirá una validación técnica del trabajo previo realizado en el proyecto Kapak, enfocándose en los modelos desarrollados por Francisco Roh. Para esto, se examinarán la documentación y los notebooks de experimentación, con el fin de identificar hiperparámetros, métricas empleadas, y supuestos que servirán de base para el estudio.



Fase 2: selección estratégica y reproducción del modelo de clasificación

A partir de los modelos previamente desarrollados para el proyecto de Kapak, se hará un análisis sistemático y comparativo de los modelos de clasificación de preguntas acusatorias. En esta evaluación se utilizarán métricas de rendimiento como AUC, F1, y analizando de manera detallada el trade-off entre identificar la mayor cantidad de riesgos posibles y reducir las falsas alarmas.

Basándose en este análisis, se van a elegir los dos modelos con mejor desempeño para utilizarlos en la construcción del indicador e índice.

Posteriormente, el enfoque será en garantizar la reproducibilidad de los modelos elegidos, asegurando que el proceso pueda ejecutarse nuevamente. Esta etapa incluirá reconstruir el pipeline, ya sea a partir del código fuente original, del dataset utilizado o de los pesos entrenados disponibles. Se concluirá esta fase cuando los resultados de los modelos coincidan en gran medida con aquellos reportados originalmente, para garantizar que funcione correctamente con nuevos datos.

Fase 3: diseño del sistema de métricas (indicador e índice)

Una vez reproducidos los modelos, el siguiente paso será diseñar la metodología del sistema de indicadores, el cual representa uno de los mayores aportes del proyecto para la detección de irregularidades. En esta fase se van a establecer la distinción conceptual entre:

- el indicador binario, basado en la clasificación de las preguntas (0/1), y
- el índice de intensidad de riesgo

Asimismo, se decidirá si sumar los resultados de cada pregunta en torno a un proceso específico para darle una calificación final de riesgo a todo el contrato o si dejarlo como por pregunta individual. Para esto se va a comparar varias formas de hacerlo, como utilizar un promedio, sumar dándole más peso a ciertas partes o simplemente quedarse con el valor de riesgo más alto encontrado en un proceso.

Este diseño metodológico servirá como guía para la parte de la programación o implementación, garantizando que lo que se planteó teóricamente funcione exactamente igual en la parte práctica.

Fase 4: Implementación computacional e integración con los datos de Kapak

En esta etapa se va a llevar a cabo la implementación computacional del indicador y el índice de riesgo definidos, integrando los modelos seleccionados con la base de datos de Kapak. Para ello se empleará el lenguaje de programación Python, junto con librerías orientadas al análisis de datos como Pandas y herramientas de conexión a base de datos, como SQLAlchemy.

El resultado de esta fase va a ser un pipeline reproducible que sea capaz de calcular el indicador y el índice de riesgo para procesos de contratación, asegurando la trazabilidad completa entre los datos de preguntas y respuestas del SOCE y los resultados finales del análisis.

Fase 5: experimentación y validación cualitativa

Por último, se va a realizar un análisis y validación de los resultados. Consiste en un análisis descriptivo que se enfocará únicamente en los procesos de Subasta Inversa Electrónica (SIE), con el objetivo de observar el comportamiento del indicador y el índice de riesgo en el periodo entre 2008-2024.

Asimismo, se realizará una validación cualitativa mediante una revisión manual de un subconjunto de datos. Esta validación consiste en un análisis de preguntas que presenten valores bajos y elevados del



índice, para corroborar si efectivamente la pregunta o comentario contiene algún tipo de cuestionamiento acusatorio. Los resultados de este ejercicio pueden sintetizarse en una matriz de confusión, lo que sirve para validar de manera empírica la capacidad del modelo para detectar irregularidades en la contratación pública.

6. Sumario de Contenidos

1. Introducción
2. Estado del arte
3. Descripción de la propuesta
4. Desarrollo del prototipo
5. Experimentos y análisis de los resultados
6. Conclusiones y trabajo futuro
7. Referencias
8. Anexos

7. Recursos

a. Humanos

Estudiante: Daniela Salazar

Tutor: Daniel Riofrío

Profesores consultores: Pavel Alba, Ricardo Flores

Consultores externos: Francisco Roh

b. Materiales

Computador personal: Lenovo modelo 81N8

Servidores de la universidad (Kapak)

c. Económicos

Uso de Claude

8. Cronograma de Actividades

Código	Actividad	Descripción	Fecha inicio	Fecha fin	Entregable asociado
A1	Planificación del proyecto	Se realiza el documento de planificación	12/1/2026	1/2/2026	Planificación



A2	Revisión del estado del arte	Búsqueda y análisis de literatura (proxys de corrupción, NLP, ML) y revisión técnica del trabajo de Francisco Roh	20/1/2026	29/02/2026	Entregable 1
A3	Revisión técnica del código previo	Revisión de notebooks, scripts, documentación, hiperparámetros y métricas	1/2/2026	29/02/2026	Entregable 1
A4	Definición de criterios de selección de modelos	Análisis de métricas, trade-off FP/FN y criterios estratégicos	15/2/2026	29/02/2026	Entregable 1
A5	Entregable 1 – Bases y selección	Redacción y entrega del documento/prototipo del a un avance del 30%	—	1/3/2026	Entregable 1
A6	Reproducción de modelos seleccionados	Reconstrucción del pipeline, validación de resultados y estabilidad	1/3/2026	20/3/2026	Entregable 2
A7	Diseño metodológico del indicador e índice	Definición formal del indicador binario y del índice de riesgo, criterios de sumatoria	10/3/2026	25/3/2026	Entregable 2
A8	Implementación	Desarrollo del pipeline en Python, integración con Kapak y SOCE	15/3/2026	28/3/2026	Entregable 2
A9	Entregable 2 – Implementación y generación del índice	Entrega del documento/prototipo a un avance del 60%	—	29/3/2026	Entregable 2
A10	Análisis descriptivo e histórico	Análisis de resultados del indicador e índice para procesos SIE (2008–2024)	30/3/2026	20/4/2026	Entregable 3
A11	Validación cualitativa	Revisión manual de subconjunto de procesos y construcción de matriz de validación	5/4/2026	20/4/2026	Entregable 3



A12	Discusión de resultados	Interpretación de hallazgos, análisis “antes vs después”	15/4/2026	24/4/2026	Entregable 3
A13	Entregable 3 – Análisis y validación	Entrega del documento/prototipo a un 90% del avance	—	26/4/2026	Entregable 3
A14	Preparación de defensa	Elaboración y práctica de la presentación	27/4/2026	3/5/2026	Defensa
A15	Defensa del Proyecto Integrador	Presentación y defensa	—	04/05/2026 – 08/05/2026	Defensa
A16	Ajustes finales del documento	Correcciones después de la defensa	9/5/2026	12/5/2026	Documento final
A17	Entrega del documento final	Entrega oficial del documento final	—	13/5/2026	Documento final

9. Entregables

Los entregables corresponden al 30%, 60%, y 90% del avance, y reflejan la secuencia del trabajo desde los fundamentos teóricos hasta el análisis y la validación final del indicador e índice de riesgo propuestos.

Entregable 1: bases teóricas y selección estratégica de modelos

Objetivo: establecer las bases conceptuales, metodológicas, y técnicas del proyecto, detallando claramente el problema a estudiar, el enfoque del análisis y los criterios que van a orientar la selección de los modelos de clasificación que se utilizarán.

Contenido

- Planteamiento del problema y justificación del proyecto
- Objetivos generales y específicos
- Revisión del estado del arte, organizada en tres ejes principales:
 - Proxys de corrupción identificados en la literatura académica y estudios prexistentes



- Técnicas de procesamiento de lenguaje natural (NLP) y machine learning aplicadas a la detección de irregularidades o riesgos en documentación gubernamental o de gestión pública
 - Revisión técnica del trabajo previo desarrollado en el proyecto Kapak, tomando en cuenta los modelos de clasificación, sus métricas de desempeño, y los resultados que se obtuvieron
- Descripción de los datos y del conjunto de datos con los que se trabajará
 - Plataforma del SOCE
 - Base de datos de Kapak
 - Tipos de información disponibles (estructurada y no estructurada)
- Selección y justificación inicial de modelos de clasificación
 - Definición explícita de los criterios de selección
 - Comparación inicial de los modelos desarrollados por Francisco Roh
- Enfoque en reproducción de resultados
 - Revisión del repositorio del trabajo de Francisco Roh (notebooks, scripts, datasets, etc)
 - Identificación y documentación de las estructuras de los modelos, parámetros de entrenamientos, y criterios de diseño (supuestos teóricos) adoptados
- Diseño conceptual inicial del sistema de métricas
 - Rol del indicador binario
 - Rol del índice de intensidad de riesgo
 - Relación entre ambos

Resultados esperados

- Estado del arte sólido
- Evaluación crítica y técnica de los modelos que fueron implementados anteriormente
- Definición de los criterios para la selección de modelos
- Diseño conceptual fundamentado del indicador y del índice de riesgo

Entregable 2: implementación del indicador y construcción del índice de riesgo

Objetivo: implementar los modelos de clasificación seleccionados y desarrollar el indicador y el índice de riesgo. El objetivo es aplicar estas herramientas sobre procesos de contratación SIE.

Contenido

- Preparación de los datos
- Reproducción y aplicación de los modelos de clasificación seleccionados
 - Obtener resultados del indicador
- Diseño final del sistema de métricas
 - Definición formal del indicador
 - Definición formal del índice de intensidad de riesgo
 - Metodología para pasar de pregunta a proceso (en el caso del índice)
- Implementación computacional
 - Pipeline de procesamiento en Python
 - Integración con la base de datos de Kapak
- Cálculo del indicador y del índice para procesos SIE
- Obtención de primeros resultados



Resultados esperados

- Modelos reproducidos y funcionales
- Indicador binario implementado y validado
- Índice de riesgo implementado y funcionando
- Dataset procesado con:
 - resultados del indicador
 - scores de riesgo por proceso
- Código documentado y reproducible

Entregable 3: análisis, validación, y evaluación del impacto

Objetivo: analizar el comportamiento del indicador y del índice de riesgo, validar su coherencia, y evaluar su utilidad para el análisis histórico y la jerarquización de procesos de contratación.

Contenido

- Análisis descriptivo e histórico
 - Indicador e índice de riesgo en procesos SIE en el periodo entre 2008-2024
- Análisis comparativo de lo que se tenía anteriormente y lo que se tiene después
 - Nuevas alertas generadas por el índice frente a información previa
- Validación cualitativa
 - matriz de validación manual en un subconjunto de procesos
 - Contraste entre el texto real, indicador e índice
- Discusión sobre los resultados y los aportes
- Identificación de limitaciones durante el proyecto
- Conclusiones y trabajo futuro
- Redacción final del documento de tesis

Resultados esperados

- Indicador e índice validados de manera empírica
- Evidencia de la utilidad del índice
- Documento de tesis prácticamente terminado

10. Referencias

Mihaly, F., & Kocsis, G. (2015). Uncovering High-Level Corruption: Cross-National Corruption Proxies Using Government Contracting Data. *SSRN Electronic Journal*. doi:10.2139/ssrn.2711932

Fazekas, M., János Tóth, I., & Peter King, L. (25 de 4 de 2016). An Objective Corruption Risk Index Using Public Procurement Data. *European Journal on Criminal Policy and Research*, 22(3). doi:10.1007/s10610-016-9308-z



- Ferwerda, J., Deleanu, I., & Unger, B. (18 de 5 de 2016). Corruption in Public Procurement: Finding the Right Indicators. *European Journal on Criminal Policy and Research*, 23(2). doi:10.1007/s10610-016-9312-3
- Decarolis, F., & Giorgiantonio, C. (2022). Corruption red flags in public procurement: new evidence from Italian calls for tenders. *EPJ Data Science*, 11(16). doi:https://doi.org/10.1140/epjds/s13688-022-00325-x
- Lima, W., Lira, R., Paiva, A., Silva, J., & Silva, V. (2023). Methodology for automatic extraction of red flags in public procurement. *IEEE International Joint Conference on Neural Network*. doi:10.1109/ijcnn54540.2023.10191683
- Modrusan, N., Rabuzin, K., & Mrcic, L. (2020). Improving Public Sector Efficiency using Advanced Text Mining in the Procurement Process. *Proceedings of the 9th International Conference on Data Science, Technology and Applications*. doi:10.5220/0009823102000206
- Faria Gomes, W., & Colaço, M. (2022). Applications of Artificial Intelligence for Auditing and Classification of Incongruent Descriptions in Public Procurement. *XVIII Brazilian Symposium on Information Systems*. doi:10.1145/3535511.3535551
- Nai, R., Morina, G., Sulis, E., Genga, L., Meo, R., Pasteris, P., & Fatima, I. (2023). AI Applied to the Analysis of the Contracts of the Italian Public Administrations. *Eindhoven University of Technology*.
- Torres-Berru, Y., López Batista, V., & Conde Zhingre, L. (2023). A Data Mining Approach to Detecting Bias and Favoritism in Public Procurement. *Intelligent Automation & Soft Computing*, 36(3). doi:10.32604/iasc.2023.035367
- Pastor Sanz, I., López Iturriaga, F., & Blanco Alcántara, D. (2024). A neural network approach for predicting corruption in public procurement. *SSRN Electronic Journal*. doi:10.2139/ssrn.5446794
- Lisciandra, M., Milani, R., & Millemaci, E. (2022). A corruption risk indicator for public procurement. *European Journal of Political Economy*. doi:10.1016/j.ejpoleco.2021.102141
- Gallego, J., Rivero, G., & Martínez, J. (2018). Preventing rather than punishing: An early warning model of malfeasance in public procurement. *International Journal of Forecasting*, 37(1). doi:10.1016/j.ijforecast.2020.06.006
- Gnaldi, M., & Del Sarto, S. (2024). Measuring Corruption Risk in Public Procurement over Emergency Periods. *Social indicators research*. doi:10.1007/s11205-024-03331-w
- Blancas, J., & Contreras, I. (2024). Global SDG composite indicator: A new methodological proposal that combines compensatory and non-compensatory aggregations. *Sustainable Development*. doi:10.1002/sd.3109



11. Revisión y firma del tutor del proyecto

Yo, Daniel Riofrío, profesor de la carrera de Ingeniería en Ciencias de la Computación, hago constar que he revisado y, por lo tanto, apruebo el documento de planificación del proyecto titulado “Diseño e implementación de un índice de riesgo de corrupción basado en preguntas acusatorias del portal de contratación pública ecuatoriano para procesos de Subasta Inversa Electrónica” propuesto por la estudiante Daniela Salazar. Por otra parte, me comprometo a proporcionar al estudiante el soporte necesario y oportuno para el buen desarrollo del proyecto antes mencionado.



Fdo: Daniel Riofrío

Quito, 1 de febrero de 2026